学　　号：2014211240　　密　级：公开

合肥工業大學

Hefei University of Technology

本科毕业设计（论文）

UNDERGRADUATE THESIS

类　　型：设计

题　　目：基于深度学习的图像匹配方法研究

专业名称：自动化

入校年份：2014 级

学生姓名：化彦伶

指导教师：朱敏　副教授

学院名称：电气与自动化工程学院

完成时间：2018 年 6 月

合　肥　工　业　大　学

本科毕业设计（论文）

基于深度学习的图像匹配方法研究

学生姓名：化彦伶

学生学号：2014211240

指导教师：朱敏　副教授

专业名称：自动化

学院名称：电气与自动化工程学院

2018 年 6 月

A Dissertation Submitted for the Degree of Bachelor

Study on Image Matching Method Based on Deep Learning

By
Hua Yanling

Hefei University of Technology
Hefei, Anhui, P.R.China
June 2018

毕业设计（论文）独创性声明

本人郑重声明：所呈交的毕业设计（论文）是本人在指导教师指导下进行独立研究工作所取得的成果。据我所知，除了文中特别加以标注和致谢的内容外，设计（论文）中不包含其他人已经发表或撰写过的研究成果，也不包含为获得 合肥工业大学 或其他教育机构的学位或证书而使用过的材料。对本文成果做出贡献的个人和集体，本人已在设计（论文）中作了明确的说明，并表示谢意。

毕业设计（论文）中表达的观点纯属作者本人观点，与合肥工业大学无关。

毕业设计（论文）作者签名：　　签名日期：　　年　　月　　日

毕业设计（论文）版权使用授权书

本学位论文作者完全了解 合肥工业大学 有关保留、使用毕业设计（论文）的规定，即：除保密期内的涉密设计（论文）外，学校有权保存并向国家有关部门或机构送交设计（论文）的复印件和电子光盘，允许设计（论文）被查阅或借阅。本人授权 合肥工业大学 可以将本毕业设计（论文）的全部或部分内容编入有关数据库，允许采用影印、缩印或扫描等复制手段保存、汇编毕业设计（论文）。

（保密的毕业设计（论文）在解密后适用本授权书）

学位论文作者签名：　　指导教师签名：

签名日期：　　年　　月　　日　　签名日期：　　年　　月　　日

摘 要

图像匹配是图像工程的基础技术，在计算机视觉、摄影测量与遥感和医学影像分析等领域都是重点研究的问题。红外图像与可见光图像匹配是多模态图像匹配的一个重要分支。红外成像系统能够在夜晚、雨雪、大雾等恶劣的环境中工作，并且可以克服在可见光下光线较暗造成可视条件差的缺点，广泛应用在目标识别、目标跟踪、军事、遥感等领域。但是由于红外图像能够反映的目标的信息过少，当需对目标图像的细节信息具体分析时，仅仅利用红外图像便不能解决实际问题。所以如果能将红外图像与可见光图像进行高精度的匹配，我们便能获得关于景象更全面的信息并且发现更多可能隐藏的信息。

本文使用深度学习的方法进行图像匹配，针对红外图像可见光图像的特征提取与匹配进行了研究并实现，本文的主要内容有以下几点：

1.阐述了图像匹配的研究背景及意义，综述了图像匹配的现有方法

2.对图像匹配技术的进行了概述，讲解了基于灰度的图像匹配算法和基于特征的匹配算法，重点介绍了基于 SURF 算子的的匹配方法，并使用 SURF 算法对红外图像与可见光图像进行了匹配实验。

3.本文对深度学习中的卷积神经网络进行了主要研究，使用卷积神经网络进行红外图像与可见光图像的特征的提取与匹配，改进了网络结构和损失函数，提出了特征融合网络。使用 tensorflow 深度学习框架搭建设计的网络，分析了特征融合网络的性能。

关键词：多模态图像匹配；SURF；深度学习；卷积神经网络

ABSTRACT

Image matching is a basic technology of image engineering. It is a key research issue in areas such as computer vision, photogrammetry and remote sensing, and medical image analysis. Matching infrared image with visible image is an important branch of multi-mode image matching. Infrared imaging system can work in harsh environments such as night, rain, snow, and heavy fog, and can overcome the disadvantage of poor visual condition caused by poor light in the visible light. So it is widely used in target recognition, target tracking, military, remote sensing and other fields. However, the infrared image can reflect too little information about the target. When we need to analyze the detailed information of the target image, the actual problem cannot be solved by only using the infrared image. So if we can match the infrared image with the visible image with high precision, we can get more comprehensive information about the scene and find more information that may be hidden.

In this thesis, image matching is carried out by the method of deep learning. The feature extraction and matching of infrared image and visible image are studied and completed. The main contents of this thesis are as follows:

1. Explain the research background and significance of image matching, and summary existing methods of image matching.

2. Review the image matching technology. Explain the image matching algorithm based on gray level and the matching algorithm based on feature, and focus on matching method based on SURF algorithm. Use SURF algorithm to match infrared image with visible image.

3. Study on the convolutional neural network in deep learning. The convolutional neural network is used to extract and match the features of infrared image and visible image. The network structure and loss function are improved, and the feature fusion network is proposed. Tensorflow deep learning framework was used to build the designed network and the performance of the feature fusion network was analyzed.

KEY WORDS: Multi-mode image matching; SURF; Deep learning; Convolution neural network

目 录

1 绪论 1
1.1 研究背景及意义 1
1.2 研究现状 2
1.2.1 基于区域的匹配方法 2
1.2.2 基于特征的匹配算法 3
1.3 介绍本文的主要工作及章节安排 3
2 图像匹配概述 5
2.1 图像匹配的概念 5
2.2 图像匹配方法的构成因素 5
2.2.1 特征空间 6
2.2.2 搜索空间 6
2.2.3 相似性度量 6
2.2.4 搜索策略 7
2.3 图像匹配算法 8
2.3.1 基于灰度的图像匹配算法 8
2.3.2 基于图像特征的匹配算法 10
2.4 实验 13
2.4.1 数据库 13
2.4.2 实验结果 14
2.4.3 实验结果分析 16
2.5 本章小结 16
3 基于深度学习的图像匹配 17
3.1 深度学习的综述 17
3.1.1 稀疏自编码器 17
3.1.2 深度置信网络 18
3.1.3 卷积神经网络 19
3.2 卷积神经网络的基本知识点 21
3.2.1 卷积层 21

3.2.2 池化层 21
3.2.3 激活函数 22
3.2.4 批尺度归一化层 23
3.3 卷积神经网络的训练过程 24
3.4 设计卷积神经网络结构 25
3.4.1 siamese 网络 25
3.4.2 特征融合网络 26
3.3 本章小结 28
4 实验与结果分析 29
4.1 软硬件环境 29
4.1.1 基本配置 29
4.1.2 深度学习框架 Tensorflow. 29
4.2 模型的训练 29
4.2.1 数据库 30
4.2.2 特征融合网络实现 31
4.2.3 训练参数讨论 32
4.2.4 实验 33
4.3 网络性能分析 34
4.3.1 评价指标 34
4.3.2 性能分析 35
4.4 本章小结 37
5 结论 38
参考文献 39
致谢 41

插图清单

图 2.1 图像匹配方法的构成因素 6
图 2.2 图像匹配流程图 8
图 2.3 积分图 11
图 2.4 三种盒子滤波器 11
图 2.5 尺度金字塔 12
图 2.6 特征点主方向的确定过程 12
图 2.7 特征描述子构造示意图 13
图 2.8 数据库 14
图 2.9 可见光图像与红外图像的匹配结果 14
图 2.10 可见光图像与红外图像的匹配结果 15
图 2.11 匹配失败的图像对 16
图 3.1 人脑视觉处理系统 17
图 3.2 稀疏自编码器 18
图 3.3 深度置信网络 18
图 3.4 卷积神经网络 19
图 3.5 局部连接示意图 20
图 3.6 下采样示意图 20
图 3.7 卷积运算图 21
图 3.8 池化层运算过程 22
图 3.9 relu 函数及其导数 22
图 3.10 lrelu 函数 23
图 3.11 训练过程流程图 25
图 3.12 siamese 网络结构图 26
图 3.13 特征融合网络结构图 27
图 4.1 测试数据库 30
图 4.2 测试数据库 30
图 4.3 数据库标签 31
图 4.4 网络文件 31

图 4.5 卷积层和 bn 层的定义 32
图 4.6 loss 曲线 33
图 4.7 准确率曲线 34
图 4.8 不同性能的分类器 AUC 值 35
图 4.9 ROC 曲线 36

表格清单

表 2.1 相似性度量方式 7
表 4.1 混淆矩阵 34
表 4.2 对不同图像噪声的抗干扰能力 37

1 绪论

视觉是人类获取信息的最重要的途径之一,人类对于图像中的信息感受效率远远超过文字、声音等其他媒介。计算机视觉就是一门研究如何让机器“看”的科学,也就是让计算机拥有对采集的二维图像进行处理,以获得目标的三维信息,从而感知世界的能力。图像匹配则是计算机视觉领域的基础问题。

1.1 研究背景及意义

图像匹配是计算机视觉领域的基础问题,通过分析图像的结构、特征及灰度等的对应关系,衡量图像间的一致性及相似性,寻求图像间的相同影像目标。这些图像可以是一种传感器在不同时间、不同角度、不同光照条件获取的,也可以来源于多种传感器。目前,图像匹配技术在计算机视觉、摄影测量与遥感和医学影像分析等领域都是重点研究的关键性和基础性问题。

从图像匹配的算法过程及应用领域来看,图像匹配技术主要应用于以下三个方面的研究:第一类是图像的配准与融合。图像匹配是图像配准与图像融合的技术基础。图像配准一般通过图像匹配技术确定一定数量对的匹配特征点,求解匹配特征点之间的空间几何变换关系。完成两幅图像的配准后,将两张图像变换到同一个坐标系下,并进行叠加融合显示[1],这就是图像融合。图像融合不仅可以显示配准的精度,而且能够在一张图上得到关于目标更多的信息。所以说图像匹配算法的性能好坏直接决定了图像配准和图像融合的精度。第二类是为立体视觉提供服务。立体视觉的主要工作是根据给定的二维图像，构建目标的三维模型。图像匹配是立体视觉系统的核心，主要是对多张不同视角的图像的进行匹配，找到他们的几何变换关系从而计算不同图像间的视差。第三类是目标识别。与人的识别过程相似,计算机对提取出的两张图片的特征点相互比较，找出能够实现匹配的若干对特征点,然后设定合适的阈值来判断是否属于同一目标。目前，图像匹配技术在人脸识别、指纹识别、图像检索等工作中得到了广泛的应用。

在国内外的应用和研究中,图像匹配已经实现了长足的发展,但成熟的图像匹配技术主要用于解决单模态匹配问题,进行匹配的图像都来自于同一个传感器。很多情况下,单一传感器能够捕捉到的信息不充分，不足以解决复杂的问题,并且普遍使用

的可见光成像系统存在工作条件苛刻、不能全天候工作等缺点,多模态图像匹配应运而生。

多模态图像匹配是指实现不同传感器获取的不同波段的图像间的匹配。红外与可见光图像匹配是常见的多模态图像匹配,红外图像一般是被动地接收地面景物的红外辐射而成的。由于红外成像能够在夜晚、雨雪、大雾等恶劣的环境中工作,并且能够在微弱的光线条件下观测,广泛应用在目标识别、目标跟踪、计算机视觉、军事、遥感等领域。但是由于红外图像能够反映的目标的信息过少,当需对目标图像的细节信息具体分析时,红外图像便不能解决实际问题。可见光图像反映的是地面景物对光线的反射率差异,图像的边缘清晰,并且能够清楚地反映景物的特征,所以如果能将红外图像与可见光图像进行高精度的匹配,我们便能获得关于景象更全面的信息并且发现更多可能隐藏的信息。由于不同传感器的成像原理和成像系统的不同,即便是满足完全相同的外界条件（在相同时间对相同区域）成像得到的可见光图像与红外图像也存在较大的差别。其次,获取图像时外界环境一般都会存在差异,图像间的对应关系总处在变化中,例如,可能存在平移、旋转和比例的变化,从而影响了匹配的精度。因此,红外图像与可见光图像匹配有着较大的难度,值得我们进行更深入的研究。

1.2 研究现状

图像匹配的概念最早是在上世纪 70 年代， 美国在针对飞行器辅助导航系统,武器投射系统等的军事研究中提出的[2]。根据实际应用的需要，人们对图像匹配技术的研究逐步深入，在提高图像匹配的精确度、实时性、通用性以及抗干扰能力等方面做了大量的改进，其应用已从原来单纯的军事应用扩展到其他领域。目前,国内外对于图像匹配的研究已经产生了不少的匹配的算法。这些算法大概分为两大类:基于区域的匹配方法和基于图像特征的匹配方法[3]。

1.2.1 基于区域的匹配方法

灰度匹配是最常用的基于区域的匹配方法。灰度匹配利用两张图像的灰度信息，通过使用某种相似性度量,如差平方和、协方差函数、相关函数等测度函数[4],判定两幅图像之间的相关性。基于图像灰度进行相关匹配能获得较高的定位精度，但是此类算法的运算量过大,对速度有要求的场合很少采用此种算法。针对匹配的计算量过大和速度较慢问题，提出了一些相关的快速算法,如 FFT 相关算法,分层搜索序列判断算法和幅度排序相关算法等。

互信息相关法是基于香农信息论的提出的。在匹配的过程中,当对应窗口两张具有共同物理结构的图像达到最佳匹配时,互信息应为最大值[5]。在对多模态图像进行匹配时,由于互信息相关法图像灰度间的关系不需作出假设,也不需对图像进行预处理和分割,所以在多模态图像匹配领域得到了广泛的关注和研究。但是互信息法忽略了图像的空间信息,同时算法的计算时间长,对噪声鲁棒性不强。

1.2.2 基于特征的匹配算法

上面的基于图像灰度的匹配方法在多模态图像匹配中常常因为多模态图像的灰度特征差异很大而难以进行实际运用。不同传感器获取的图片虽然在灰度上的差异很大,但是仍然保留了基本的物理结构,而基于图像特征的匹配方法利用了图像的高层特征信息,因此更适合多模态图像的匹配分析。

基于特征的匹配算法提取的图像特征有轮廓、边缘、角点等。角点是最早被使用到匹配中的图像特征。1977 年，Moravec 提出了 Moravec 角点检测算子[6]，该算法将像素周边的一个邻域作为一个窗口,计算这个窗口和周围几个方向上窗口的灰度差的平方和，选取最小值为兴趣值，如果兴趣值大于设定阈值该点就是候选角点。1988 年，Harris 对 Moravec 算法进一步改进，提出了被广泛使用的 Harris 角点检测子，该算法能够对多个方向上的角点进行检测[7]。之后，Smith 等人提出一种近似于人类视觉观察过程的角点检测算子 SUSAN。2004 年,Lowe 正式提出了 SIFT 算法,此算法通过对图像进行不同程度的模糊与缩放,在不同尺度的图像中提取特征点[7],具有对旋转、光照、缩放、视角改变等的多量性、稳定性、独特性，但是 SIFT 算法运算量过大，影响算法的实时性。2006 年 Bay 等人提出了 SURF 算法[8],该算子用 Hessian 矩阵来提取图像的特征点，并且引入了积分图的概念，性能超过了 SIFT，计算速度是 SIFT 的三倍，其后的一段时间内,又出现了 Brief[9]和 ORB[10]算法。他们的速度更快,识别率更高。

国外对红外与可见光图像匹配的研究主要开始于 20 世纪 90 年代初,而国内关于红外与可见光图像配准的研究就相对于国外要晚一些,大部分工作都 2000 年以后发表的,且研究深度还远远不够。由于红外与可见光各自的特性,到目前为止,有效的方法还比较少,大部分都是针对特定应用而独立研究的一些方法。所以,红外与可见光图像匹配的还需要我们的继续深入研究。

1.3 介绍本文的主要工作及章节安排

本文首先介绍了图像匹配算法的发展现状，讲解了图像匹配的基本理论以及常

用算法，并且使用 SURF 算法对红外图像和可见光图像进行了实验，接着介绍了深度学习的原理和深度学习的几种模型，重点讲解了卷积神经网络的结构，然后提出了能对红外图像和可见光图像精确匹配的特征融合网络。

本文的章节安排如下：

第一章分析了图像匹配的研究背景及意义，综述了图像匹配的的现有方法

第二章介绍了图像匹配的基本概念和原理，分析了基于灰度的图像匹配算法和基于特征的匹配算法，重点介绍了基于 SURF 算子的的匹配方法，并对红外图像与可见光图像的匹配结果进行分析。

第三章阐述了深度学习的背景原理，简述了深度学习的三种常用模型，并且讲解了卷积神经网络的网络结构、训练过程，之后介绍了本文使用的特征融合网络，分析了具体的网络结构和损失函数。

第四章使用 tensorflow 深度学习框架搭建了特征融合网络，给出了实验结果，并分析了特征融合网络的性能。

2 图像匹配概述

图像匹配是计算机视觉和图像处理中一个重要的研究内容。本章主要对图像匹配进行简要概述,介绍了图像匹配算法的构成因素,并且综述了图像匹配的主要算法。

2.1 图像匹配的概念

匹配,通常是对两组数据集合进行分析处理,找出他们之间的对应关系,从而衡量两组数据集合之间的相关性。图像匹配就是指在多幅图像中寻找与给定目标图像最相似的图像,或者在图像区域中寻找最相似的子区域的过程。一般将实际获得的进行匹配判断的图像成为目标图像，而将已知的给定图像称为模板图像。如果将两张需进行匹配的图像分别表示为二维矩阵向量 $I_1(x,y), I_2(x,y)$，其中 I_1 为模板图像，I_2 为目标图像，这两个向量分别代表图像对应坐标(x, y)处的灰度值，那么图像匹配的过程可表示为：

$$I_2(x,y) = p(q(I_1(x,y))) \tag{2-1}$$

式中函数 $p(x,y)$ 表示图像间的灰度变换关系，$q(x,y)$ 表示图像间的空间变换关系。

从公式(2.1)可以看出,图像匹配的过程进行的是两种形式的变换:其一是图像间的灰度变换。不同的图像传感器由于成像方式不同，实际工作的波段范围不同，得到的图像往往有很大差异。即使是同一传感器在对同一目标进行拍摄时，拍摄时间的不同、光照条件的变换也会导致图像灰度的差异。其二是空间几何变换，由于相机拍摄视角的不同，目标的几何结构、位置不停的变化等原因，几何变换在两图像间普遍存在。

2.2 图像匹配方法的构成因素

由于在获取图像时，选取的成像传感器不同，拍摄时所处的时间和场地的不同，以及传感器本身的缺陷等原因，所得的图像往往存在很大的差异。针对不同形式的图像匹配问题，人们相继提出了各种算法，这些算法适用于各种场合，解决了许多实际问题。虽然各种图像匹配算法应用的领域及处理的问题不同，但是都是每个算法都是由特征空间、搜索空间、相似性度量和搜索策略四个要素组成[11]，他们之间的关系如图 2.1 所示，

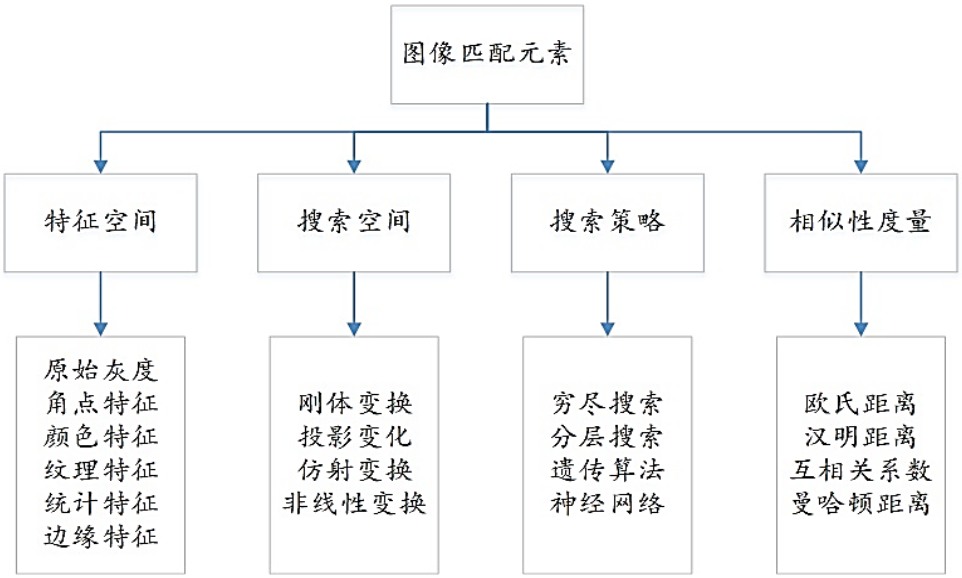

图 2.1 图像匹配方法的构成因素

2.2.1 特征空间

计算机在对图像进行较高层次的处理时，首先要提取图像的特征。图像实际就是一个二维数据的集合，但其中包含了丰富的信息，例如，基本的图像的灰度信息、梯度信息，图像的角点、轮廓、边缘信息，图像的统计信息等。这些信息适用于不同的算法，对于基于区域的图像匹配算法会用到图像的灰度、区域信息，而基于特征的匹配算法则是使用图像的高层信息，图像的特征点、线、面等。

图像特征的提取是图像匹配算法的第一步，选取合适的特征是匹配算法成功的首要条件。一般要求提取的特征有以下特点：

(1) 提取的特征抗干扰能力强、鲁棒性强

(2) 特征易于提取，运算量小

(3) 能够适用于各种图像

(4) 适合于选取的匹配算法

2.2.2 搜索空间

搜索空间其实就是两张图片之间的变换关系的集合。根据图像间变换关系的使用范围可分为局部变换范围和全局变换范围。图像间的变换模型包括线性变换和非线性变换。其中常用的线性变换模型有刚体变换、投影变换、仿射变换。

2.2.3 相似性度量

图像经过空间变换后，就需要根据相似性度量[12]来衡量变换效果，并且控制接下来变换关系的选择以及使用的搜索策略。相似性度量方式的选择与特征空间和空间

变换的形式紧密相关，不同的特征形式一定程度上决定了不同的相似性度量方式，而相似性度量的结果则直接影响了之后选择的变换关系。一般经常使用的相似性度量有两类，一类是距离测度，包括欧式距离、闵可夫斯基距离、汉明距离等；另一类是相关性度量，用于基于灰度的图像匹配算法。表 2.1 是对以上方法简要介绍：

表 2.1 相似性度量方式

测度方式	具体方式	公式表达	适用情况
距离测度	欧式距离	$dis=\sqrt{\sum_{i=1}^{n}(x_i-y_i)^2}$ n 表示向量 x, y 的维度	描述多维特征之间的真实距离，简单直接
	汉明距离	$dis=\sum_{i=1}^{n}x_i\oplus y_i$ 距离表示码字 x，y 在相同位置上码符不同的数目总和，反映的是两个码字之间的差异性	主要用于二进制特征匹配
	曼哈顿距离	$dis=\sum_{i=1}^{n}\lvert x_i-y_i\rvert$	计算复杂度低，但鲁棒性不好
相似系数测度	相关系数	$c(i,j)=\frac{\sum_{i=1}^{M}\sum_{j=1}^{N}R(x+i,y+j)\bullet T(x,y)}{\sqrt{\sum_{i=1}^{M}\sum_{j=1}^{N}R^2(x+i,y+j)\bullet\sum_{i=1}^{M}\sum_{j=1}^{N}T^2(x,y)}}$	常用于基于灰度的图像匹配，鲁棒性好，运算量大

2.2.4 搜索策略

搜索策略是指在搜索空间中寻找最优空间变换关系的方法，直接影响了匹配算法的速度和精度。常用的搜索策略有穷举搜索法、神经网络、黄金分割法、三次插值法等。穷举搜索法通常可以满足相对较小的特征空间的匹配要求，但是当提取的特征

空间较大时，这种算法存在运算量大、运算时间长等缺点，不适用于对实时性有要求的场合。

总的来说，当设计图像匹配算法时，我们要根据图像间的显著特征选择合适的特征空间，在相似性测度的控制下，选择适合的搜索策略和搜索空间，从而找到两张图像的最佳匹配点。

2.3 图像匹配算法

图像匹配的过程一般是先向匹配系统中输入模板图像和目标图像，然后分别提取两张图像的相同形式的特征，经过空间变换后，用相似性测度衡量特征点之间的距离，相距最近的位置便是最佳匹配位置。图 2.2 便是图像匹配的整个流程：

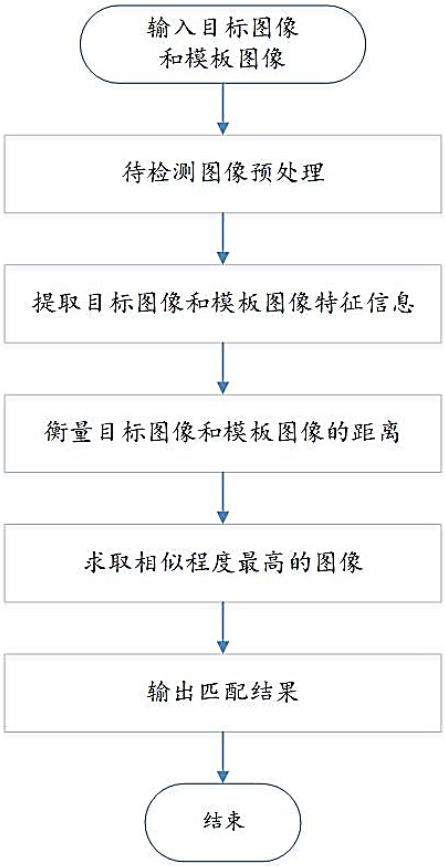

图 2.2 图像匹配流程图

根据算法提取的特征形式的不同，分为基于灰度的匹配算法和基于特征的匹配算法[13]。

2.3.1 基于灰度的图像匹配算法

基于灰度的图像匹配算法采用的图像信息为灰度，不需要进行特征检测。下面介绍几种常用的基于灰度的匹配算法：

(1) MAD 算法、SAD 算法、SSD 算法、SAD 算法

这几种算法具有一定的相似性，都是根据模板图像与灰度图像在相应区域中所有点的灰度差的大小来衡量相关性。

MAD 算法又叫做平均值绝对误差法。假设模板图像为$I_1(x,y)$，大小为$S\times T$，目标图像为$I_2(x,y)$，大小为$s\times t$，MAD 算法可由式 2-2 表示

$$Q(x,y)=\frac{1}{S\times T}\sum_{m=1}^{S}\sum_{n=1}^{T}\left|I_1(x+m-1,y+n-1)-I_2(x,y)\right| \tag{2-2}$$

其中：$1\le x\le s-S+1$，$1\le y\le t-T+1$

SAD 算法全称为误差和算法，度量公式如式 2-3 所示

$$Q(x,y)=\sum_{m=1}^{S}\sum_{n=1}^{T}\left|I_1(x+m-1,y+n-1)-I_2(x,y)\right| \tag{2-3}$$

其中：$1\le x\le s-S+1$，$1\le y\le t-T+1$

SSD 算法全称为误差平方和算法，度量公式的基本形式与上相同，只不过 SSD 算法采用的不是绝对距离，而是两点之间的欧氏距离，如式 2-4 所示

$$Q(x,y)=\sum_{m=1}^{S}\sum_{n=1}^{T}\left|I_1(x+m-1,y+n-1)-I_2(x,y)\right|^2 \tag{2-4}$$

其中：$1\le x\le s-S+1$，$1\le y\le t-T+1$

MSD 算法叫做平均值误差和算法，度量公式如式 2-5 所示

$$Q(x,y)=\frac{1}{S\times T}\sum_{m=1}^{S}\sum_{n=1}^{T}\left|I_1(x+m-1,y+n-1)-I_2(x,y)\right|^2 \tag{2-5}$$

其中：$1\le x\le s-S+1$，$1\le y\le t-T+1$

上述的几种方法是最早的灰度匹配方法，理解起来相对容易，在实际应用时具有较高的运算精度。但是由于算法要求遍历图像中的每一个像素点，当图像像素较大时运算量过大，影响算法的实时性，并且这些算法对噪声等干扰很敏感。

(2) NCC 算法

归一化积相关算法简称 NCC 算法，该算法采用两图像对应像素点的灰度信息，计算两者之间的相关性，NCC 算法可由式 2-6 表示

$$R(i,j)=\frac{\sum_{S=1}^{M}\sum_{t=1}^{N}\left|S^{i,j}(s,t)-E(S^{i,j})\right|\bullet\left|T(s,t-E(T))\right|}{\sqrt{\sum_{S=1}^{M}\sum_{t=1}^{N}\left[S^{i,j}(s,t)-E(S^{i,j})\right]^2\bullet\sum_{S=1}^{M}\sum_{t=1}^{N}\left[T(s,t)-E(T)\right]^2}} \tag{2-6}$$

其中，$E(S^{i,j})$、$E(T)$分别为(i,j)目标子图和模板图像的平均灰度值

(3) SSDA 算法

针对以上算法运算量过大的缺点， Barnea 和 Sliverman 于 1972 年提出了 SSDA 算法[14]，全称为序贯相似性检测算法。算法具体的流程如下：

首先定义式 2-7 所示的图像间像素点之间的绝对误差函数

$$\varepsilon(i,j,s,t)=\left|S_{i,j}(s,t)-\bar{S}_{i,j}-T(s,t)+\bar{T}\right| \tag{2-7}$$

其中，带有上划线的函数分别表示目标子图和模板图像的均值

$$\bar{S}_{i,j}=E(S_{i,j})=\frac{1}{M\times N}\sum_{s=1}^{M}\sum_{t=1}^{N}S_{i,j}(s,t) \tag{2-8}$$

$$\bar{T}=E(T)=\frac{1}{M\times N}\sum_{s=1}^{M}\sum_{t=1}^{N}T(s,t) \tag{2-9}$$

然后计算模板图像区域内随机点的像素值与对应目标图像像素值的绝对误差 ε，将随机点的绝对误差累加直到超过了设置的阈值 U，记下选用的随机点的个数，也就是累加次数 k，全部的子图的累加次数用$W(i,j)$表示，如式 2-10 所示

$$W(i,j)=\left\{H\left|\min_{1\le k\le M\times N}\left[\sum_{h=1}^{\mathrm{k}}\varepsilon(i,j,s,t)\ge U\right]\right.\right\} \tag{2-10}$$

如果在两图像的某个对应点处，随着累加点数的增加，累计误差很快达到阈值，那么这个点便不是匹配点。最佳匹配点处随着累加点数的增加，累计误差应该增加的比较缓慢。

2.3.2 基于图像特征的匹配算法

基于图像特征的图像匹配方法[15]常用的图像特征包括点、线、面等，整个算法的基本流程如下：提取两证图像中的特征信息，然后对提取出的特征进行描述，最后进行特征匹配。目前，人们已经提出了多种特征点提取算子，最早的 Moravec 角点检测算子，改进后的 Harris 算子，SIFT 算子，SURF 算子等。SURF 算子是在 SIFT 算子的基础上改进得到的，对图像间的尺度变化、旋转、光照具有一定的稳定性，并且相对 SIFT 算子来说，计算量小，速度快。接下来将详细介绍基于 SURF 算法的图像匹配方法[16]。

(1) 特征提取

SURF 算法采用了积分图[17]的概念，使得高斯二阶微分滤波与图像卷积可通过积分图的加减运算完成。假设图像中任意一点的像素值为$I(x,y)$，积分图中任意一点(x',y')值$s(x',y')$为以原图像左上角位置与点(x',y')连线为对角线的矩形内的所有点的像素值之和，用式 2-11 所示表示

$$s(x',y')=\sum_{x=0}^{x'}\sum_{y=0}^{y'}I(x,y) \tag{2-11}$$

这样求解图像中的任意一个矩形内像素值和的运算就可以用几个积分图的加减运算来实现，如图 2.3 所示，

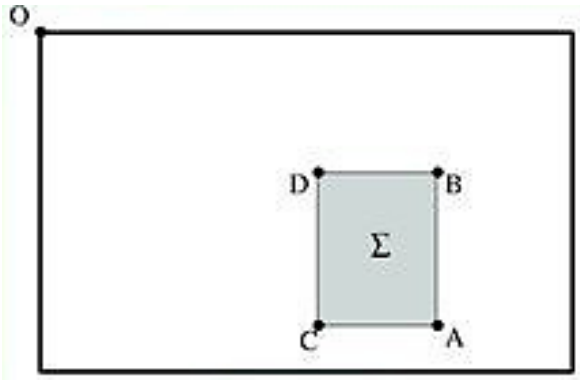

图 2.3 积分图

A、B、C、D 分别为矩形区域四个点在积分图上的对应值，阴影部分面积由式 2-12 表示

$$\sum = A-B-C+D \tag{2-12}$$

SURF 算子利用 Hessian 矩阵来提取图像中的特征点，图像某个点的 Hessian 矩阵定义如式 2-13 所示

$$H(x,\sigma)=\begin{bmatrix} L_{xx}(x,\sigma) & L_{xy}(x,\sigma) \\ L_{xy}(x,\sigma) & L_{yy}(x,\sigma) \end{bmatrix} \tag{2-13}$$

上式中 L_{xx}、L_{xy}、L_{yy} 分别为图像与高斯滤波函数卷积后在各个方向上的二阶微分值。σ 为尺度变换因子，它保证了提取出的图像特征点具有尺度不变性。

使用 Hessian 矩阵提取特征点时，首先要对像素点进行高斯滤波，然后再求解各个方向上的二阶导数。如图 2.4 所示，SURF 算法中用 9×9 的盒子滤波器近似代替尺度为 σ =1.2 的高斯二阶微分滤波器

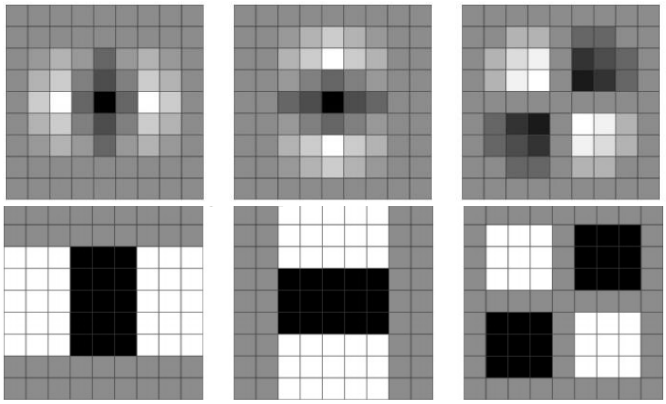

图 2.4 三种盒子滤波器

Hessian 矩阵的行列式可近似由式 2-14 表示

$$\det(H(x,\sigma)) = D_{xx}D_{yy} - (0.9D_{xy})^2 \tag{2-14}$$

D_{xx}、D_{xy}、D_{yy} 为盒子滤波器与图像的卷积。上式中的 0.9 时在 σ=1.2 尺度下，为了保持盒子滤波器与高斯二阶微分滤波器的相似性而设定的。这样我们便求出了不同尺度下图像的 Hessian 滤波响应。特征点的定位则需要构建尺度空间。与 SIFT 算法不同的是，SURF 算法通过改变盒子滤波器的尺度大小来构建尺度金字塔，没有对图像进行降采样[18]，如图 2.5 所示，左图为 SIFT 算法使用的图像金字塔，右图为 SURF 算法尺度金字塔：

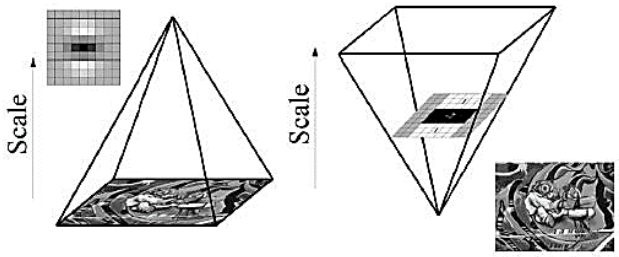

图 2.5 尺度金字塔

(2) 特征描述

特征点的初步定位通过探测某像素点周围同一组内相邻层间 26 个点，比较此像素点的 Hessian 响应是否为 26 点的的最大值或最小值，如果是则作为初步特征点。这时得到的特征点位置和尺度不够精确，可采用 3 维线性插值法来确定极值点的精确位置，同时去除特征点小于阈值的点。

SURF 算法通过统计特征点邻域内的 Harr 小波特征来确定特征点的主方向。假设该点所在的尺度为 r，在半径为 6r 的圆内，选择边长为 4r 的 Haar 小波，统计 60 度扇形边界内全部点的水平 Haar 小波特征和垂直 Haar 小波特征总和。之后以一定的角度间隔旋转 60 度扇形重复以上步骤，最后将扇形的方向最大值作为该特征点的主方向，如图 2.6 所示，最右边的确定的即是特征点主方向。

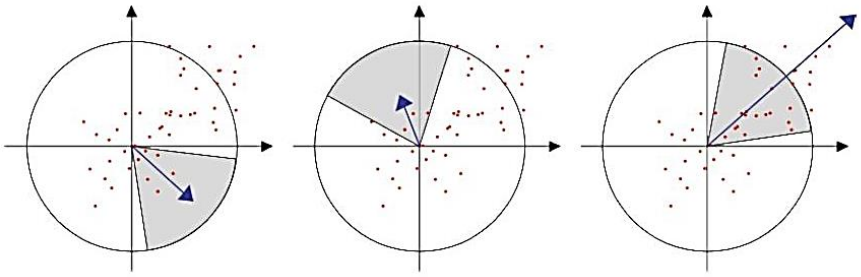

图 2.6 特征点主方向的确定过程

构建特征描述子的过程如下。在特征点周围取一个边长为 20r 正方形框，上一步检测出的特征点主方向为正方形框的方向，将框分割成 4×4 的子区域，每个子区域有 5×5 个像素，统计每个区域内的水平 Haar 小波特征和垂直特征，最终得到了 64 维的特征描述子。示意图如图 2.7 所示：

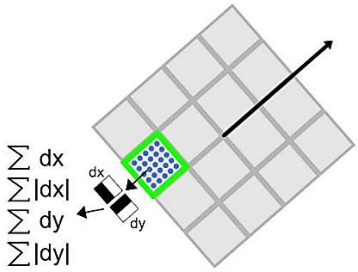

图 2.7 特征描述子构造示意图

(3) 特征匹配

使用两个特征向量之间的距离来进行匹配，当特征向量之间的距离小于设置的阈值则为匹配特征点。

2.4 实验

基于 SURF 的图像匹配首先用 SURF 算法提取两张图像的特征，然后进行特征匹配。本次实验，仿真实验软件环境为 win10 系统，Matlab R2016a；硬件环境为 CPU Intel Core 2.2GHz 的 PC 机。

2.4.1 数据库

实验采用的测试图片来自 IVRL 实验室的 RGB−NIR 数据库，包含场景的可见光图像和对应的红外图像，现场类别有国家，田野，森林，室内，山，古建筑物，街道，城市，水。数据库中的图像使用尼康 D90 和佳能 T1i 相机拍摄，利用 B+W486（可见光）和 093(NIR)滤光镜来获取可见光和红外图像，格式为.tiff 文件。使用 B+W486 滤光片时，88%的紫外光波在 380 纳米处被阻挡，95%的红外光在 700 纳米处被阻挡，这有助于确保落在数码相机传感器上的光仅限于可见光谱。B+W093 滤光器可以阻挡可见光和紫外光波来捕捉场景的红外光照射图像，允许大约 88%的波长在 900nm 以上的红外光进入所安装的镜头。

使用 matlab 将互联网数据库进行格式转换、切割、排序之后得到的数据库如图 2.8 所示，每张图像的像素都为 64×64，格式为.bmp，同一场景的红外图像与可见光图像相邻，例如 1 和 2，3 和 4，5 和 6 等分别为同一场景对应的可见光图像和红外图像，总计 2000 张

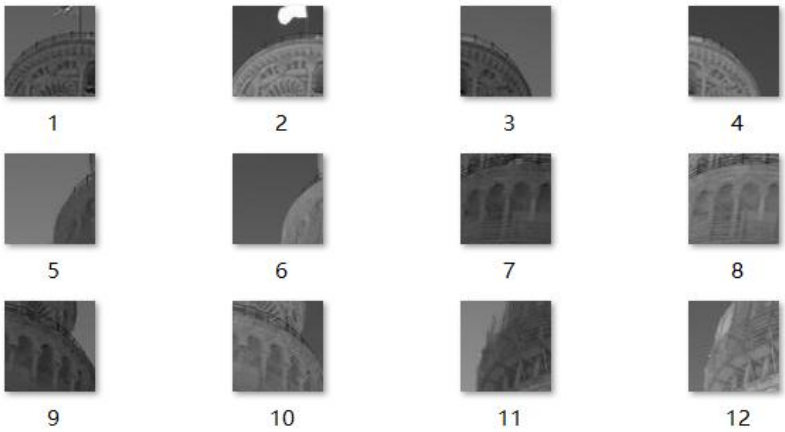

图 2.8 数据库

2.4.2 实验结果

将红外图像与所有的可见光图像进行关键点匹配，思路如下：将可见光图像归一化到相同大小，提取关键点，并描述关键点处的 SURF 特征；将红外图像归一化到与可见光图像相同的大小，提取 SURF 特征点，然后逐个计算红外图像与可见光图像每两个特征点的特征向量间距离，小于一定阈值且方向满足一定要求的则认为是匹配成功，记录两幅图像能够匹配的特征点数目。将红外图像与数据库中所有的可见光图片都进行上述的匹配过程，选取匹配特征点最多的可见光图片，该图像便是场景的红外图像对应的可见光图像。

具体实现过程如下：

步骤一：将图像的名称信息放到 info.txt 文件中，如图 2.9 所示。每一行分别为同一场景对应的可见光图像和红外图像，第一列为可见光图像列，第二列为红外图像列。

图 2.9 可见光图像与红外图像的匹配结果

步骤二：读取 info.txt 文件信息，数组 a1 存储可见光图像名称信息，数组 a2 存储红外图像名称信息。利用数组 a2 红外图像名称信息，一次读取一张红外图像，之

后与 a1 中的所有可见光图像进行匹配，匹配特征点最多的便判定为对应的同一场景的可见光图像，当此时两个对象位于数组 a1、a2 的同一位置，则匹配正确。

数据库中有 1000 个场景的可见光图像及其对应的红外图像，对 1000 张红外图像的匹配结果进行统计，有 459 张匹配正确，也就是匹配特征点最多的两张图像为同一场景的红外和可见光图像，如图 2.10 所示

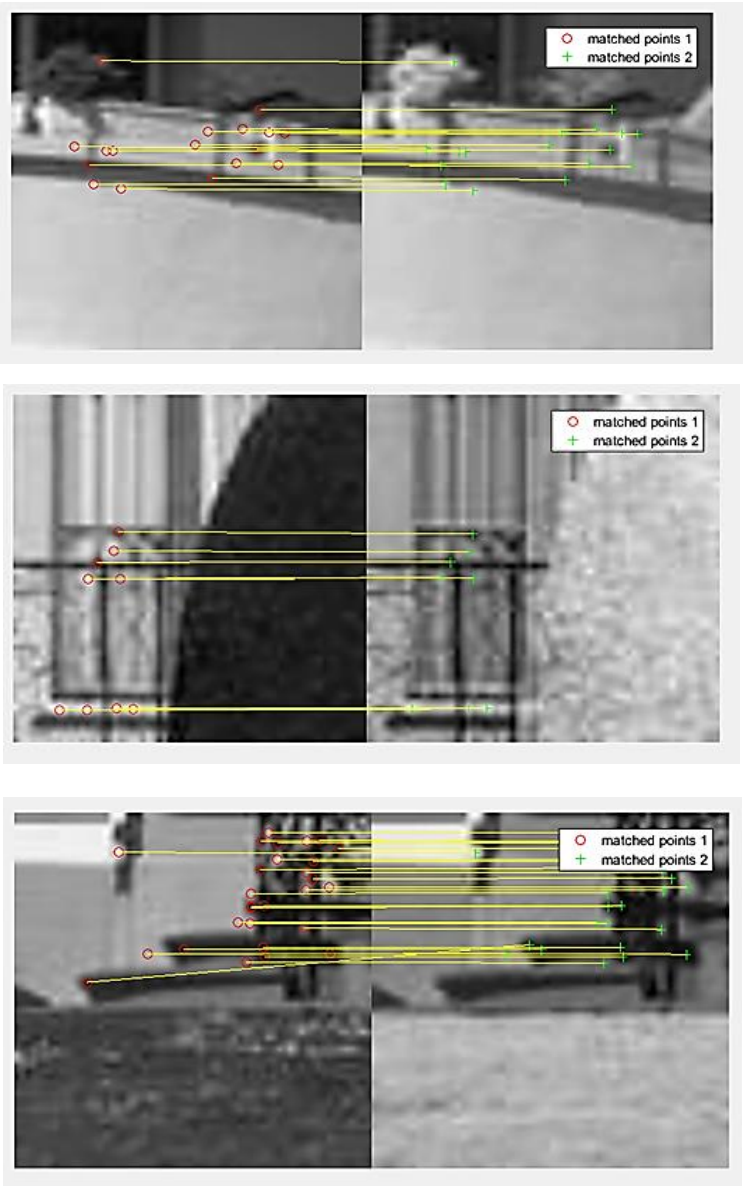

图 2.10 可见光图像与红外图像的匹配结果

由图 2-10 可见，基于 SURF 的图像匹配方法可以进行可见光图像与红外图像的匹配，能够提取到两种图像的共同特征。但是这种方法也存在相当的局限性，如图 2.11 所示，数据库中有些场景的红外图像与可见光图像灰度上几乎完全成负像，提取到的两张图像的特征点的方向相反，导致匹配失败。

图 2.11 匹配失败的图像对

2.4.3 实验结果分析

实验可知，基于 SURF 算法的图像匹配对红外图像和可见光图像的匹配效果不是很好。分析原因可能有以下几点：

(1) 由于可见光图像和红外图像成像原理不同，波谱的范围不同，体现在灰度上有较大差异，存在同一场景的可见光图像和红外图像几乎灰度完全相反的情况

(2) 红外图像相对可见光图像信息表现不明显、对比度低，检测出的特征点较少，导致能够匹配的特征点较少。

2.5 本章小结

本章首先简要介绍了图像匹配的基本概念和原理，讲解了图像匹配的空间变换模型和图像匹配算法的构成因素，然后对常用的图像匹配算法进行了总结分析，重点介绍了基于 SURF 算子的的匹配方法，并且使用 SURF 算子对红外图像与可见光图像进行了匹配实验。由于基于 SURF 算法的图像匹配方法对可见光和红外图像的匹配性能不高，所以接下来考虑使用深度神经网络来进行特征点提取与匹配。

3 基于深度学习的图像匹配

深度学习属于机器学习的范畴，在图像处理领域得到了广泛的应用[19]。特征提取是图像处理中的重要环节。在传统的机器学习算法中，特征的提取通常需要大量的人工干预和复杂的算法，运算量大而且效率并不高。深度学习可通过组合多层网络结构，自动地学习图像的深层特征信息。目前，深度学习已是许多领域的研究热点。

3.1 深度学习的综述

深度学习的研究动机在于模拟人脑处理信息的过程，构建多层机构神经网络。生物学家发现人脑处理图像的过程采用了分层机制，物体在视网膜上成像之后，经过多层神经元，逐层提取物体的特征。如图 3.1 所示，V1 层根据视网膜上的像素点首先提取物体的边缘信息，V2 层则根据 V1 层提取出的边缘信息来构造更高级的特征，获得物体的基本形状信息，到 V4 就可实现对视网膜上的成像物体的识别。

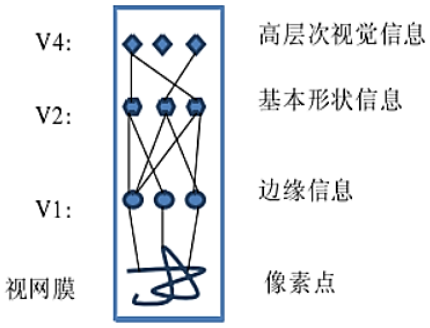

图 3.1 人脑视觉处理系统

深度学习是在人工神经网络的基础上发展而来的，能够以多层网络结构来模拟复杂函数，足够深的网络结构是深度学习的一大特点。以下是几种深度学习网络结构的介绍。

3.1.1 稀疏自编码器

自编码器能够学习到无标签数据的特征，是用来构造 $\hat{x} = x$，也就是输出等于输入的函数。图 3.2 是一种自编码器的结构，最终实现 $h_{W,b}(x) = x$ 的功能。当网络中的隐藏层的神经元个数少于输入输出神经元个数时，自编码器可以实现对输入数据维度的压缩，学习到能够代表输入数据结构的更重要的因素。当隐藏层的神经元个数大于输入神经元时，可向自编码器中引入稀疏限制，便是稀疏自编码器[20]。假设隐藏层某神经元针对输入 x_i 的输出为 $a_j(x_i)$，当 $a_j(x_i)$ 的值接近 1 是，神经元被激活，当 $a_j(x_i)$ 的值接近 0 时，神经元被抑制。稀疏自编码器就是通过向损失函数中加入稀疏惩罚

因子，限制隐藏层中一些神经元的激活，使其处于抑制状态，从而在隐藏层神经元个数较多时仍能得到输入数据的重要结构。

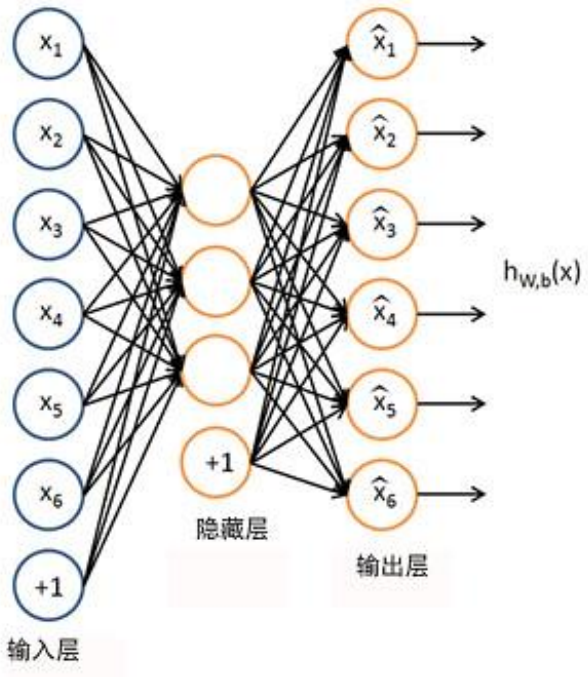

图 3.2 稀疏自编码器

3.1.2 深度置信网络

深度置信网络是由多个受限玻尔兹曼机（RBM）组合而成。图 3.3 是一种深度置信网络的结构，由于 RBM 的主要作用为特征提取和降维，所以在深度置信网络的最后一层会增加 BP 网络作为分类器。在网络训练时，通常是首先进行逐层进行无监督地 RBM 层训练，最后有监督地 BP 网络训练[21]。

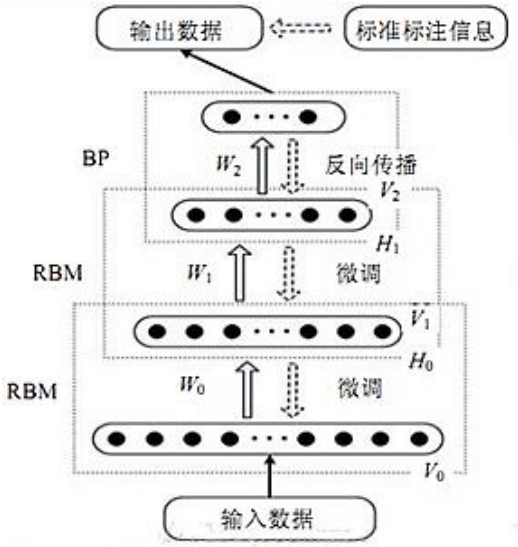

图 3.3 深度置信网络

3.1.3 卷积神经网络

CNN 与一般神经网络的不同之处在于，CNN 网络包括了由卷积层和池化层组成的特征抽取器，能够实现特征的提取和降维，图 3.4 是一个卷积神经网络，C1、C3 为卷积层，S1、S2 为采样层。卷积神经网络相邻层间的神经元不像 BP 网络一样与上一层的全部的神经元连接，某层神经元仅与上层的部分神经元连接，这样大大减少了网络中的参数个数。

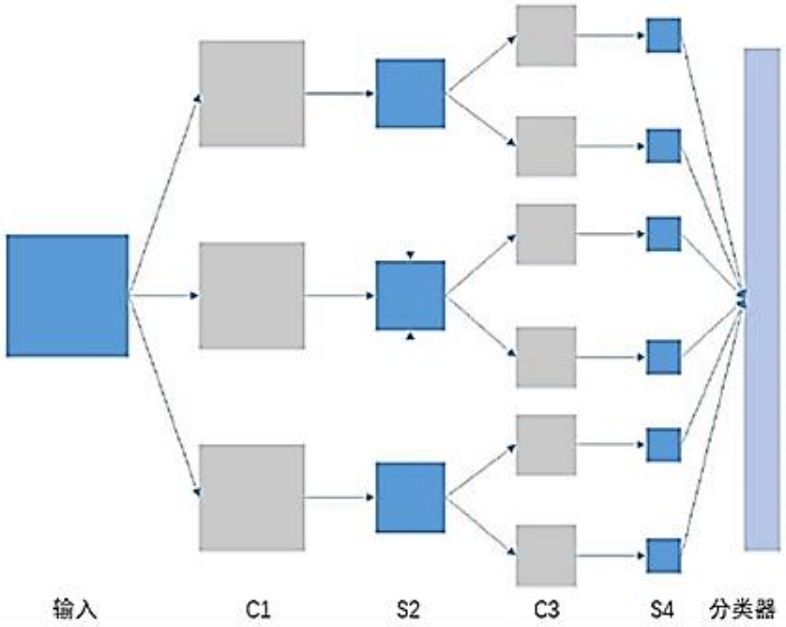

图 3.4 卷积神经网络

卷积神经网络解决了传统神经网络的全连接和梯度弥散的问题。CNN 的核心思想有以下三点：局部感知，权值共享，下采样。

局部感知。形象地说，局部感知[22]类似于人眼的观察过程，当我们观察场景时，目光首先聚焦于场景中的局部区域，之后目光的扫射区域慢慢移动，遍布整个场景。在普通的多层感知器中，隐藏层网络节点会连接到一张图像的全部像素点上，而在 CNN 中，每个隐藏层节点只连接到图像特征图中某个局部区域的像素点上，从而需要训练的权值参数大大减少。

按照传统的人工神经网络，将输入图像的像素展开成一维矩阵之后，每一个像素值就相当于一个神经元输入，要对每一层隐藏层和输出层进行全连接。在 CNN 网络中引入了卷积的概念，卷积核对原图像或特征图上符合卷积核大小的像素加权求和，图 3.5 是卷积神经网络的局部连接示意图。

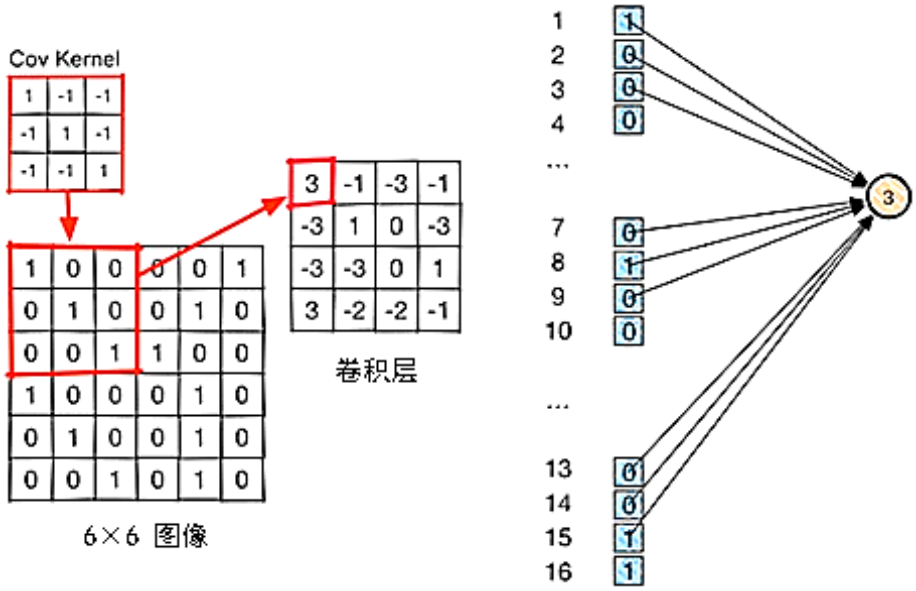

图 3.5 局部连接示意图

权值共享。局部连接减少了需要训练的权值参数，但是计算量仍很大。权值共享的提出很大程度的解决了这一问题[23]。对于同一张图像或者不同图像，图像中会出现很多相同特征，使用同一个卷积核提取存在的相同特征便能进一步减少参数数量。假设卷积核的大小为 10×10，有 10×10 个参数，当输入图像像素大小为 1000×1000 时，10^6 个神经元共享同一卷积核，也就是说不管输入神经元的大小为多少，需要训练的参数都为 10×10 个，这个规则适用于整个神经元网络。当我们需要提取不同的图像特征时，可以采用不同类型的卷积核，每个卷积核对应提取不同的特征。

下采样。在 CNN 网络中，下采样可进一步减小图像的规模，从而减少了训练参数及运算量，降低了过拟合的发生[24]。如图 3.6 所示，图像大小为 500×500，采用最大池化，池化层规模为 2×2，经过池化后，图像像素减低为 250×250，而且基本保持了图像特征。

图 3.6 下采样示意图

3.2 卷积神经网络的基本知识点

本文基于深度学习的图像匹配采用卷积神经网络结构，利用卷积神经网络进行图像特征的提取。卷积神经网络是为识别二维图像而设计的一个多层网络结构模型，网络中的每一层都通过训练数据隐式地学习图像的特征，这种网络模型能够保持对平移、缩放、旋转或者其他变形的高度稳定性。本节是对卷积神经网络的基本结构的简要介绍。

3.2.1 卷积层

在数字滤波器中，卷积滤波器的形状一般是对称的，否则要先对滤波器权值进行左右对折。在卷积神经网络中，卷积核一般不符合对称形式，所以在进行卷积运算前首先要进行卷积核的镜像操作。卷积核实际上是权值参数的矩阵形式，矩阵的每个元素与输入层或者隐藏层的相同形式的像素点进行加权求和，得到相应的特征图。卷积运算可由式 3-1 表示：

$$x_j^h = g(\sum_{i \in M_j} x_j^{h-1} \times k_{ij}^h + b_j^i) \tag{3-1}$$

上式中 x_j^{h-1} 表示当前卷积运算操作层像素值，k_{ij}^h 表示卷积核 (i, j) 处的权值参数，b_j^i 为偏置值，$g(x)$ 表示采用的激活函数。

卷积层一般采用多个卷积核来提取图像的多种特征，遵循局部感知和权值共享的原则。图 3.7 为一个卷积核的卷积运算图，原图像大小为 5×5，卷积核大小为 3×3，默认采用的步长为 1，不填充边界，最终得到的特征图大小为：$(5-3+1)\times(5-3+1)=2\times2$。

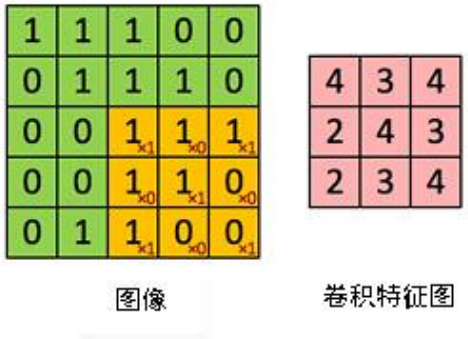

图 3.7 卷积运算图

3.2.2 池化层

池化层一般位于卷积层之后，对相邻的一组像素做相应的操作，压缩卷积运算之后特征图的尺寸，实现降维的目的。常用的池化方式有：最大值池化、平均池化、最

小值池化等，这几种方式是分别对池化层卷积核运算范围内的相邻神经元进行取最大值、平均值、最小值的操作。图 3.8 是最大值池化的运算过程，原图像尺寸为 4×4，池化后图像大小为 2×2：

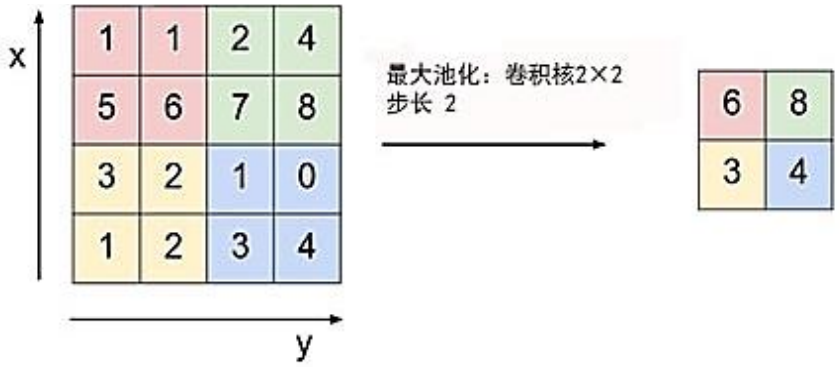

图 3.8 池化层运算过程

3.2.3 激活函数

上面介绍的卷积、池化操作相当于对原图像的线性操作，不论采用几层卷积层、池化层，整个网络都是线性的。当我们处理一些复杂问题时，线性模型便不能解决实际问题。卷积神经网络引入激活函数，向网络中加入非线性因子，使得网络具有更好的表达能力。sigmoid 和 tanh 由于存在梯度弥散的问题，使用量较少，目前常用的激活函数 relu、lrelu 等。

近几年 relu 是很受欢迎的一种激活函数，它的定义如式 3-2 所示：

$$y = \max(0, x) = \begin{cases} 0, x < 0 \\ x, x \geq 0 \end{cases} \tag{3-2}$$

由图 3.9 可知，当 $x \geq 0$ 时，relu 的导数始终为 1，解决了梯度弥散的问题，相对 sigmoid 和 tanh 有较快的收敛速度。但是当 $x < 0$ 时，函数的导数为 0，在网络训练的过程中某一神经元可能会出现梯度始终置零，无法进行权值更新的情况。

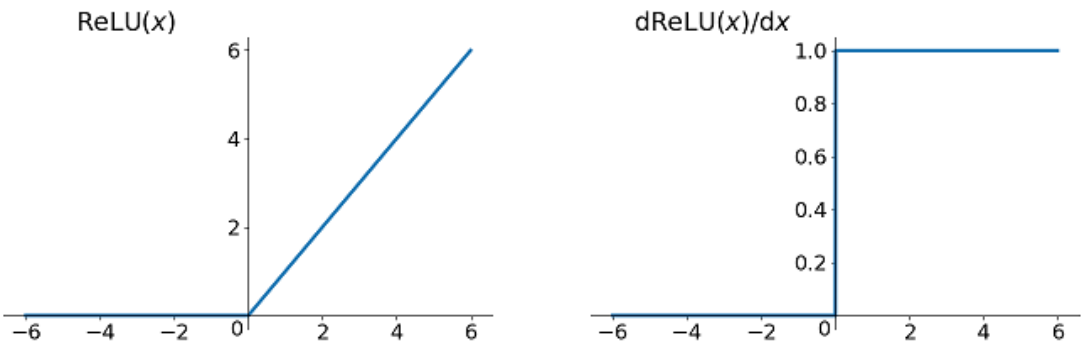

图 3.9 relu 函数及其导数

lrelu 是在 relu 激活函数上进行的改进，定义如式 3-3 所示下：

$$y=\begin{cases}\alpha x, x<0\\ x, x\geq 0\end{cases} \tag{3-3}$$

上式中，α 是一个很小的常数，其图像如图 3.10 所示：

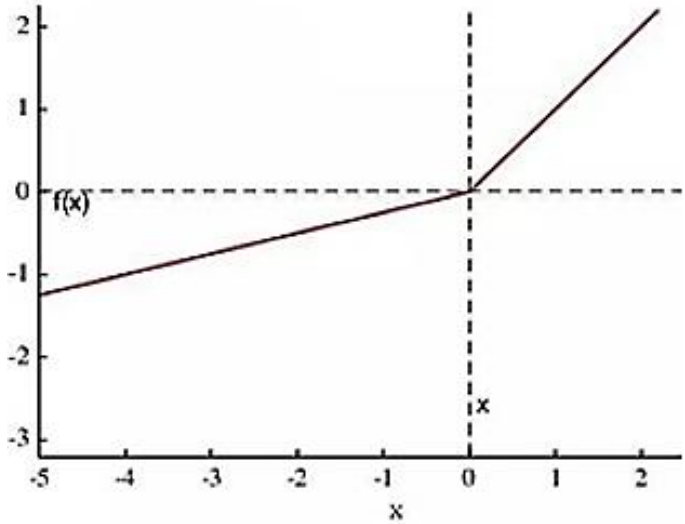

图 3.10 lrelu 函数

由图像可知，当 $x\geq 0$ 时，lrelu 的导数始终为 1；当 $x<0$ 时，函数的导数为数值很小的常数 α 。lrelu 改变原来 relu 的结构，避免了梯度的消失，并且合适的 α 并不会影响网络的性能。

3.2.4 批尺度归一化层

在卷积神经网络训练之前，通常要对输入图像进行归一化处理，目的在于：使训练数据集和测试数据集有相同的数据分布，提高网络的泛化能力；加快网络的训练速度。对于深度网络来说。在网络训练的过程中，反向传播使得网络中除了输入层外的每一层的输入数据分布一直处于变化之中，这样便会减慢训练速度。批尺度归一化层（BN 层）的提出解决了这一问题。

BN 层一般加在每层的输入前，既能对每层输入神经元进行归一化处理，又能保持每层网络学习到的特征分布，其前向传播过程为：

输入：

某一批次的输入神经元：$P=\{x_1,x_2...,x_m\}$，m 为批次输入神经元大小

需要学习的参数 γ,β

输出：

批归一化后的值 $S=\{y_i=BN_{\gamma,\beta}(x_i)\}$

流程：

计算此批次的输入神经元的均值

$$\mu_P = \frac{1}{m}\sum_{i=1}^{m} x_i \tag{3-4}$$

计算此批次的输入神经元的方差

$$\sigma_P^2 = \frac{1}{m}\sum_{i=1}^{m} (x_i - \mu_P)^2 \tag{3-5}$$

批归一化

$$\hat{x}_i = \frac{x_i - \mu_P}{\sqrt{\sigma_P^2 + \varepsilon}} \tag{3-6}$$

变换重构

$$y_i = \gamma \hat{x}_i + \beta \tag{3-7}$$

3.3 卷积神经网络的训练过程

卷积神经网络训练实际上为了获得输入与输出间映射关系的过程，通过监督学习，向网络中输入大量的形如(x, t^m)的样本对，使得网络的的输出y^m尽可能地接近输入对应的标签t^m。在训练 CNN 之前，要对网络初始化，将每层网络的权值随机初始化为较小数值，以免因网络权值过大导致网络进入饱和状态。CNN 的训练主要包括两个阶段：前向传播和后向传输。前向传输将样本对中的x输入网络，经过卷积、池化等得到实际输出y^m。一次前向传输完成后，便进行反向传递来更新网络权重。利用损失函数计算实际输出y^m与输入样本对的期望输出t^m之间的误差，采用链式求导计算损失函数对每个权重的梯度，然后根据梯度下降公式更新权重，多次迭代之后，网络训练完成。图 3.11 是 CNN 训练过程的流程图。

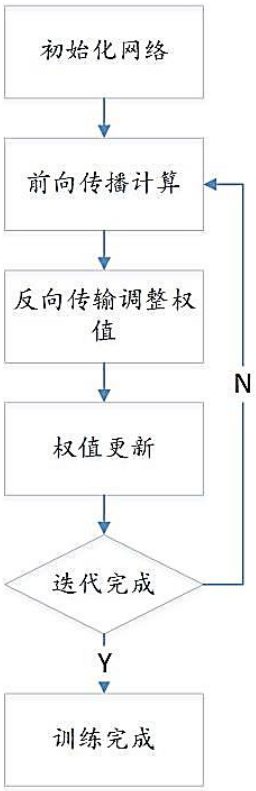

图 3.11 训练过程流程图

3.4 设计卷积神经网络结构

本文使用卷积神经网络来实现红外图像与可见光图像匹配。卷积神经网络的性能将直接影响图像匹配的精度，不恰当的神经网络往往会导致模型的欠拟合或过拟合。当网络层数过少时，构造的模型不能充分提取训练样本的深度特征，不足以对样本进行很好的拟合。当网络中的特征提取层数过多时，训练的模型在训练样本上显示了很好的性能，网络的输出与预测输出基本一致，但是将此模型运用到测试样本上时，测试的准确率却很低。所以，设计一个能很好地提取图像特征并且不会过拟合的网络是研究的重点。

目前，卷积神经网络在目标检测、目标识别等方面已经展示了很好的性能，但在图像匹配方面的应用较少。因此，本文借鉴了传统的签字识别网络 siamese 的网络结构，并在此基础上进行了改进，设计了特征融合网络。

3.4.1 siamese 网络

最初，siamese 网络是用来实现签字识别的网络，判别两个字体是否来自同一个人。算法的原理图如图 3.12 所示，网络分为两个部分，第一部分为特征提取网络，第二部分为根据提取的特征进行相似度测量。特征提取网络分为两个分支，这两个分

支具有相同的网络结构，并且权值共享，分别提取两张图片的特征。网络的最后一层对两分支提取的特征进行相似性度量，从而判断是否属于同一类别。

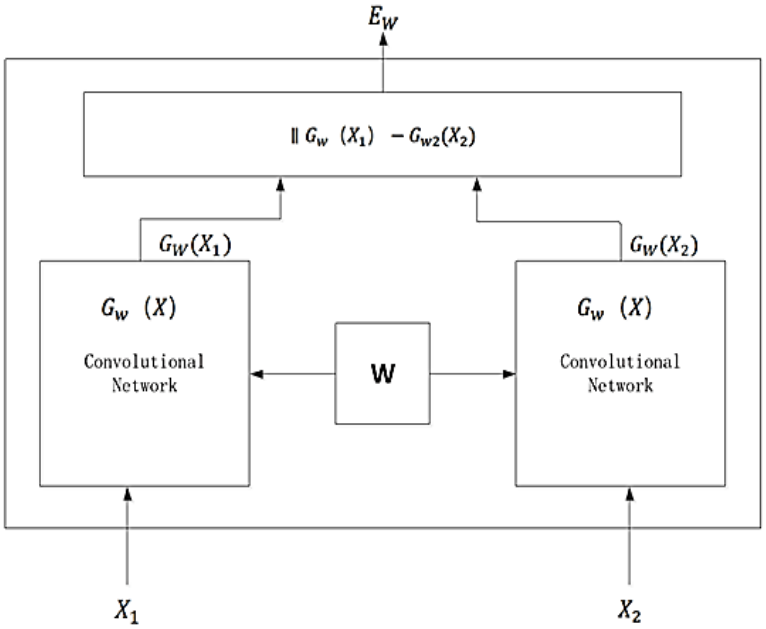

图 3.12 siamese 网络结构图

输入为类似(X_1, X_2, Y)的样本对，X_1，X_2为需要判断进行类别判断的两张图片，Y为期望输出，当X_1，X_2为相同类别时Y为 0，否则为 1。X_1，X_2经过卷积神经网络得到特征向量$G_w(X_1)$，$G_w(X_2)$，使用$E_w(X_1, X_2) = \|G_w(X_1) - G_w(X_2)\|$比较两个特征向量。对于损失函数，为了实现最小化损失函数时，减少相同类别的损失能量，增加不同类别的损失能量，设计如下的损失函数的形式：

$$L(W,(Y,X_1,X_2)^i) = (1-Y)L_G(E_W(X_1,X_2)^i) + YL_I(E_W(X_1,X_2)^i) \tag{3-7}$$

其中$(Y, X_1, X_2)^i$为第 i 个样本对，L_G计算相同类别输入的损失函数，L_I计算不同类别的损失函数。只要将L_G设计为为单调递增函数，L_I设计为单调递减函数，便可用以上形式的损失函数训练网络。

3.4.2 特征融合网络

卷积神经网络的模型结构的设计主要参考训练数据库的大小、训练样本的类别、网络训练的目的等，同时也要总结前人经验。本文设计的网络目的是为实现红外图像和可见光图像的相似度判别，网络的输出直接反映两者的相似度。网络分为两个部分，第一部分为设计一个特征提取网络，两分支权值共享，分别提取两输入图像特征。由于小卷积核的叠加能够减小网络参数并且引入更多的非线性，所以采用多个 3×3 大小的卷积层叠加代替大卷积核的卷积层。第二部分将特征提取网络的两分支特征

进行融合决策。根据以上思想，参考 siamese 网络，设计的特征融合网络结构如图 3.13 所示：

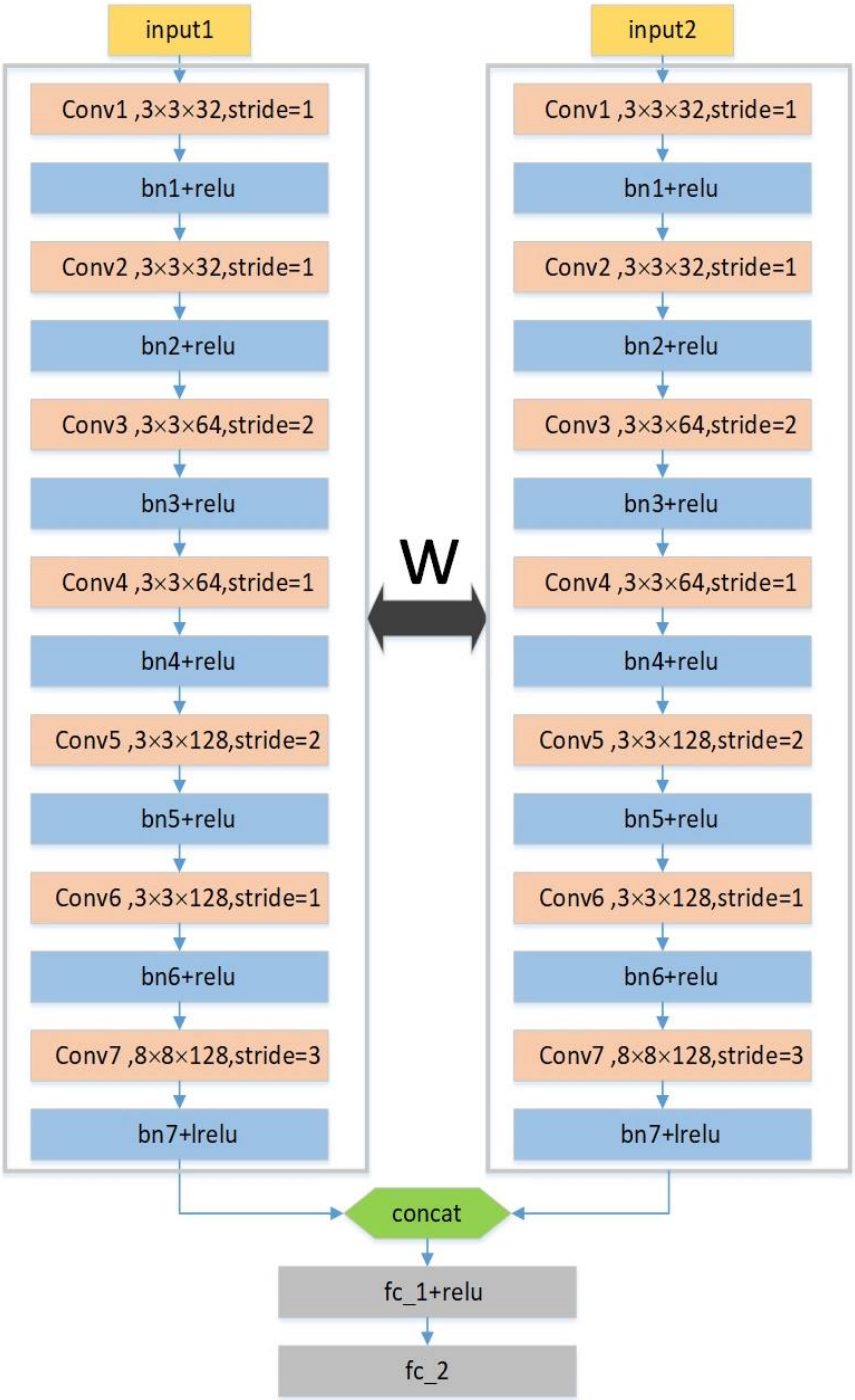

图 3.13 特征融合网络结构图

输入为两张 64×64 的灰度图像。第一层为卷积层，32 个卷积核，大小为 3×3，步长为 1，默认的 padding 方式为‘SAME’，输出特征图尺寸为 64×64。第二、四、六、八、十、十二、十四层结构相同，都为批尺度归一化层，将输入该层的同一批次

的特征图进行归一化，能大大加快网络训练速度，之后采用 relu 激活函数，使网络非线性化，并且降低了网络过拟合的概率。第三层卷积层有 32 个大小为 3×3 的卷积核，采用的步长为 1，该层输出特征图大小为 64×64。第五层卷积层每个像素与上一层的 9 个像素相连，卷积核大小为 3×3，步长为 2，64/2=32，则该层输出特征图的大小为 32×32，共 64 张。第七层卷积层卷积核大小为 3×3，采用的步长为 1，输出 64 张特征图，大小为 32×32。第九层卷积层有 128 个卷积核，大小为 3×3，采用的步长为 2，根据 32/2=16，输出特征图尺寸为 16×16，共 128 张特征图。第十一层每个像素与上一层的 9 个像素相连，采用的步长为 1，则特征图的大小为 16×16，共 128 张特征图。第十三层为卷积层，共 128 个 8×8 大小的卷积核，padding 方式为‘VALID’，步长为 1，根据$(16-8+1)/3=3$得，输出特征图尺寸为 3×3。此时每个分支得到的特征图尺寸为$3\times3\times128$，将两分支特征图矩阵形式重新调整为一维向量并且连接这两个一维数组，维度为$3\times3\times128\times2=2304$。之后采用两个全连接层对融合矩阵进行决策，输出神经元个数为 1。

损失函数可以估量网络模型的预测值与真实值的相差程度，它是一个非负函数，损失函数越小，模型的鲁棒性就越好。在反向传播过程中，通过最小化损失函数来更新网络权重。本文采用的损失函数类似于交叉熵函数，目的在于实现实际输出接近期望输出时 loss 函数的分布很低，可用下式表示：

$$\text{loss}=\sum_{i=1}^{m}-(y_i\times\log(sigmoid(\hat{y}_i))+(1-y)\log(1-sigmoid(\hat{y}_i))) \qquad (3\text{-}8)$$

上式中 y_i 为样本标签， y 为实际输出。

3.3 本章小结

本文阐述了深度学习的背景原理，简述了深度学习的三种常用模型，并且讲解了卷积神经网络的网络结构、训练过程，之后详细介绍了本文改进的特征融合网络，分析了具体的网络结构，给出了采用的损失函数。

4 实验与结果分析

本章将对设计的特征融合网络进行实验，并对网络的性能进行分析。第一节介绍了本次实验的软硬件环境；第二节展示了神经网络的训练过程；第三节对本文用到的评价指标进行说明，并且分析了网络的性能。

4.1 软硬件环境

4.1.1 基本配置

本次实验是在 Ubuntu 操作系统下完成，采用 Tensorflow 来搭建深度学习框架，软件环境为 PyCharm，主要使用的编程语言是 python。在硬件方面，为了支持深度学习训练方面的要求，所用的电脑搭载了 Nvidia GTX1080ti 显卡。

4.1.2 深度学习框架 Tensorflow

Tensorflow 是由谷歌在 2015 年发布的开源的深度学习框架，最初是用来进行神经网络方面的研究，但是由于本身强度大的通用性，使其广泛应用于其他计算领域。

Tensorflow 的名称来源于自身的运算过程。Tensor 代表多维数组，flow 代表 tensor 在数据流图中的计算过程，所以深度学习框架 Tensorflow 就是输入 tensor 在数据流图中从图的开始流到结尾的数据计算过程。Tensorflow 是一个采用计算图的形式来表示数值计算的系统，图中的每个节点都表示一种数学计算，每条线代表节点间的依赖关系。Tensorflow 程序通常分为构建图和运行计算图两部分。在图的构建阶段，节点 op 的执行过程被描述成了图的形式。计算图构建完成后，创建 session()对象来启动图的计算过程。

本文采用 Tensorflow 来搭建深度学习框架，是因为 Tensorflow 有以下优点：

充足的算法库：Tensorflow 支持卷积神经网络，循环神经网络，深度强化学习及计算密集的科学计算，并且有关于深度学习的充足的 API，包括搭建神经网络的各种网络层次，如卷积、池化、全连接等，矩阵向量运算以及可视化工具 Tensorboard 等。

高度的灵活性：Tensorflow 可以在 windows、linux 等多种系统中运行，支持 CPU 和 GPU 两种运行模式，但是基于 GPU 的运行模式运行速度远远超过 CPU。

支持多种语言：TensorFlow 支持 Python 和 C++两种编程语言，再复杂的多层神经网络模型都可以用 Python 来实现。

4.2 模型的训练

4.2.1 数据库

训练模型采用的数据库与第二章采用的数据库来源于同一互联网数据库。这个数据集由 477 张 9 类可见光 RGB 和红外图像(NIR)组成，场景类别有:国家, 田野, 森林, 室内摆设, 山, 建筑物, 街道, 城市, 水，图像的格式为.tiff 文件。经过格式转换、切割、排序之后，得到 2.2 万张大小为 64×64 的.bmp 图片，其中训练数据库 2 万张，如图 4.1 所示，测试数据库 2000 张，如图 4.2 所示，对应的.txt 文件中存储着图像的像素信息。

图 4.1 测试数据库

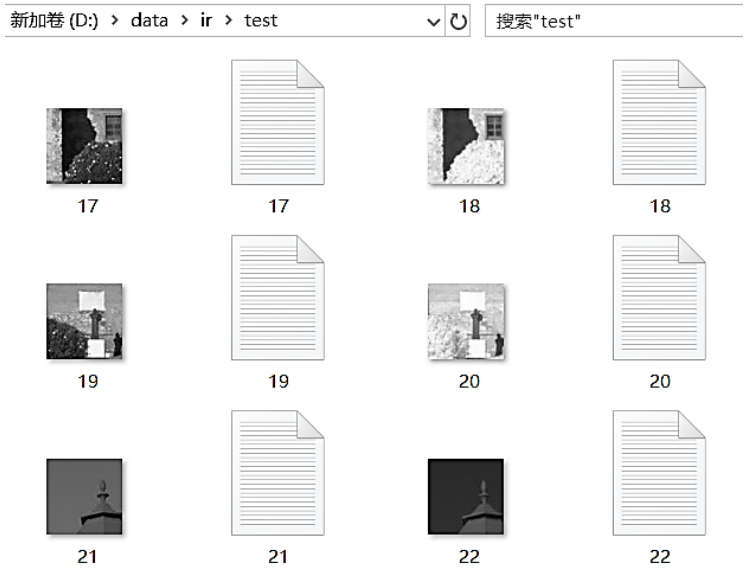

图 4.2 测试数据库

由以上两图可见，同一场景的红外图像与可见光图像相邻，对应的标签信息存储在 info.txt 文件中，如图 4.3 所示。每一行对应着数据库中图像的类别信息，相同数字分别代表同一场景的可见光图像和红外图像。

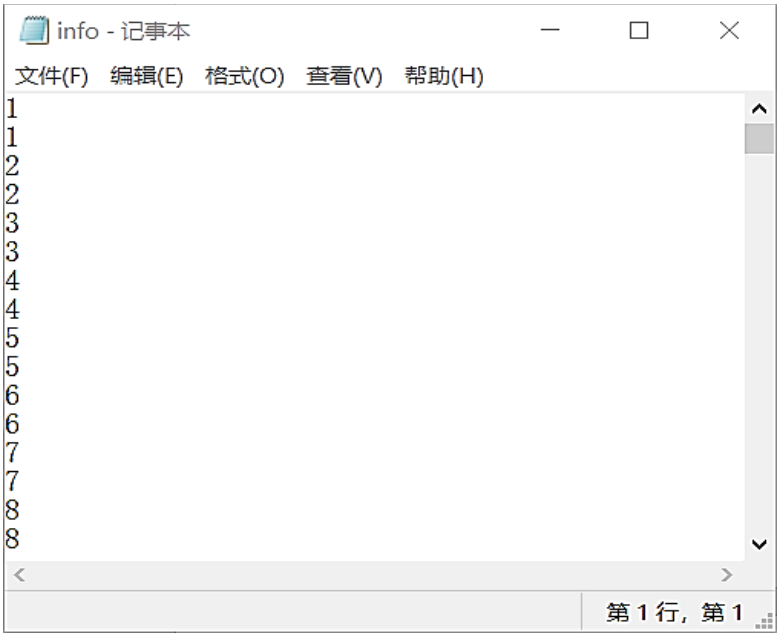

图 4.3 数据库标签

4.2.2 特征融合网络实现

本次实验采用了 7 层卷积层的卷积神经网络，具体的网络结构已在 3.3.2 小节中介绍。使用深度学习框架 tensorflow 来搭建并训练特征融合网络，软件环境为 PyCharm, 主要使用的编程语言是 python，网络文件如图 4.4 所示

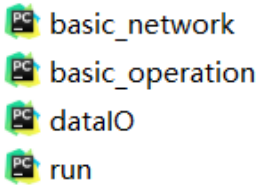

图 4.4 网络文件

dataIO.py 是网络的数据输入接口文件，定义了三个函数，分别为：read_data(self,dir,start,end)用来读取数据库图片和标签信息，orgnize_data(self,size,ratio)构造正负样本对，next_batch(self,step,batchSize)获取迭代过程中每一批次的数据。

baisc_operation.py 定义了网络中使用的卷积层，bn 层的参数及具体使用形式，如图 4.5 所示。

```
def conv2d(self,input,filter,kernel,stride,padding='SAME',layer_name='conv',bath_norm=True):
    with tf.name_scope(layer_name):
        conv=tf.layers.conv2d(inputs=input,filters=filter,kernel_size=kernel,strides=stride,
                              padding=padding,
                              kernel_initializer=tf.contrib.layers.xavier_initializer())
        return conv
def Batch_Normalization(self,x, training, scope):
    with arg_scope([batch_norm],
                   scope=scope,
                   updates_collections=None,
                   decay=0.9,
                   center=True,
                   scale=True,
                   zero_debias_moving_mean=True):
        return tf.cond(training,
                       lambda: batch_norm(inputs=x, is_training=self.training,reuse=None),
                       lambda: batch_norm(inputs=x, is_training=self.training,reuse=True))
```

图 4.5 卷积层和 bn 层的定义

basic_network.py 实现了特征提取网络的构建，采用 7 层卷积层用来提取图像的特征，每一卷积层后添加 bn 层加快收敛速度。

run.py 包含训练过程中的主函数，cal_record(fc,label,batch_size,ratio)通过比较特征融合网络的输出与标签的大小来判断网络对正负样本对的预测是否正确，match_net()首先构造了完整的特征融合网络，定义了采用的损失函数和反向训练网络的方式，之后实现了网络的训练和测试，调用 cal_record 判断预测情况，采用的方式是边训练边测试，执行 match_net()便可开启网络的训练与测试。

4.2.3 训练参数讨论

初始学习率。卷积神经网络的反向传播通过使用优化器最小化损失函数来更新网络中的参数权值。本次实验选用 AdamOptimizer 优化器，原因如下：相比较 SGD，AdamOptimizer 能自动调整不同的参数的学习率，加速网络的收敛速度；对梯度的均值和未中心化的方差进行综合考虑，而不是直接由当前梯度决定。一般，将 AdamOptimizer 的学习率初始值设为 0.001 便能达到很好的效果。

批大小。批大小是卷积神经网络的一个重要参数，决定了反向传播梯度的下降方向和大小。一般来说，较大的批尺寸会加速网络的收敛过程，梯度下降的方向更加准确，并且提高内存的利用率。但是训练过程中，过小的批尺寸导致网络的收敛速度过慢，甚至可能陷入局部极值，然而过大的批尺寸占用过多的内存，反而使得训练的速度变慢。所以，根据网络的复杂度和数据库大小，最终确定批大小为 128。

停止训练的条件。实验中采用了边训练边测试的方式，经过观察发现网络经过 20 个 epoch 左右便可实现 loss 值基本下降到 0.1 左右，变化不大，故设定网络的进行 20 个 epoch 的训练。

4.2.4 实验

实验中，网络对输入样本进行决策后判断正负样本的阈值为 0，大于 0 为正样本。样本的正负比例各占一半，batchsize 为 128，也就是一次迭代向网络中输入 128 对样本对，遍历 2 万个样本需要 156 次，2 个 epoch、312 次迭代后，重新打乱训练数据库，再次进行以上迭代步骤，总共完成 20 个 epoch，1716 次迭代。

图 4.6 是神经网络在训练时的 loss 曲线图，loss 表示实际输出与期望输出间的误差。由于每 312 次迭代重新打乱训练数据库，所以会在打乱处出现 loss 突变，但整体来看，loss 值实现了快速收敛，考虑是由于 bn 层的作用，并且最终 loss 值可以稳定在 0.1 左右。

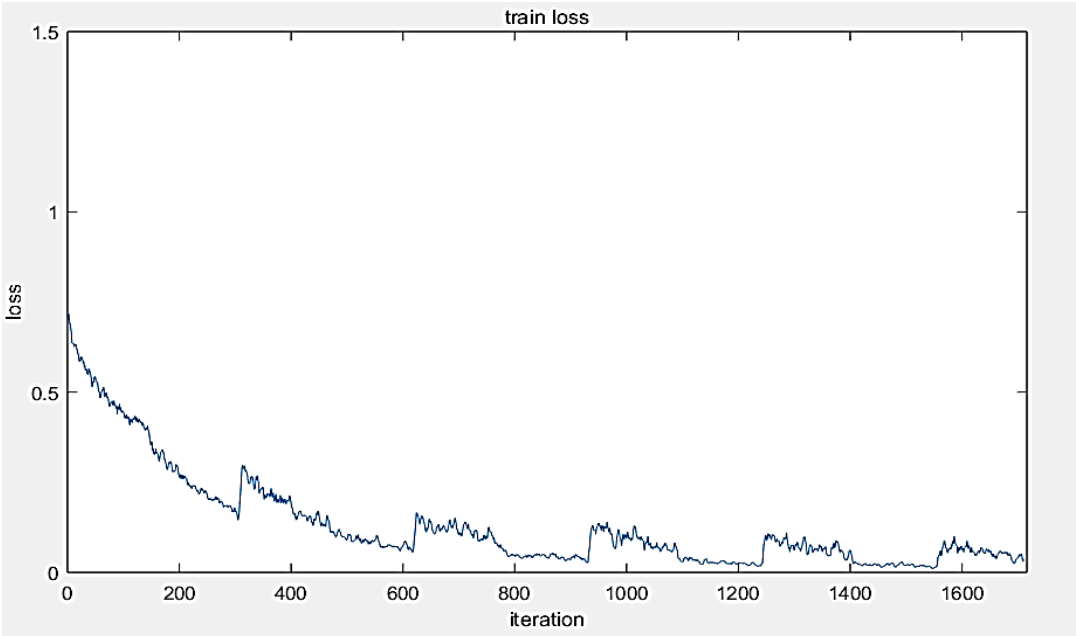

图 4.6 loss 曲线

输入图像对经过网络决策并进行正负样本判断之后的结果与输入标签值进行比较，相同则判断正确，准确率便是判断正确的图像对占输入图像对比例。训练过程中训练数据库的准确率的收敛曲线如图 4.7 所示，模型训练开始时，网络对输入样本随机评估，准确率大约在 0.5 左右，最终准确率可达到 99%左右。

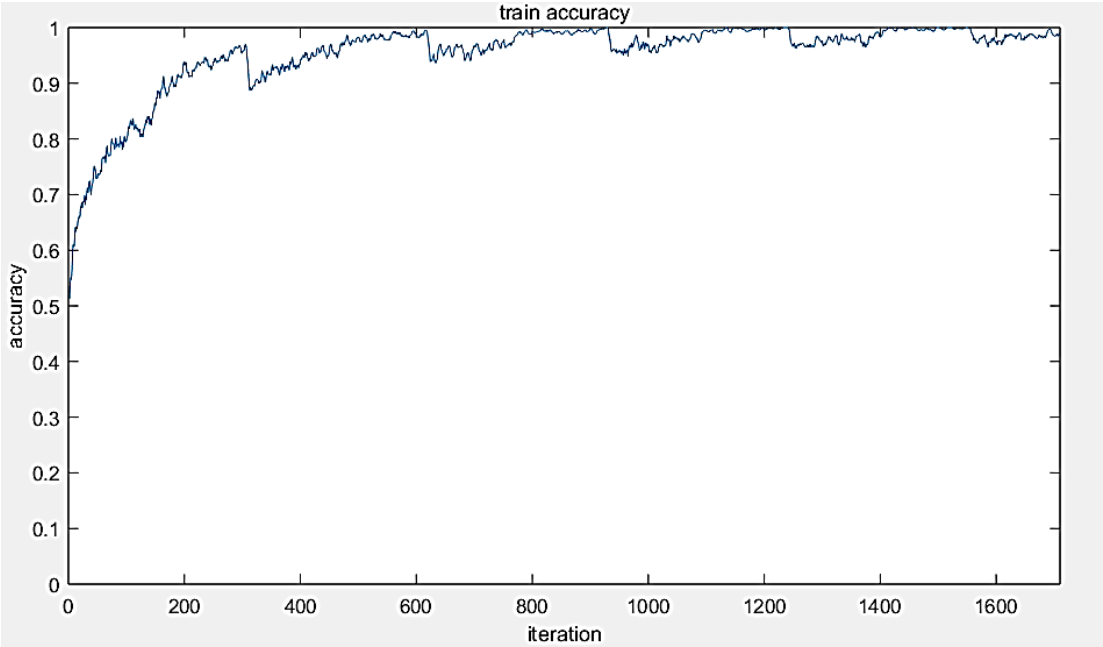

图 4.7 准确率曲线

使用训练好的模型在测试数据库上的测试结果为 95%，相较在训练数据库性能有所降低，但特征融合网络已较好的完成了实验目的。

4.3 网络性能分析

4.3.1 评价指标

本文采用以下几个评价指标分析经训练过后的网络的性能：

混淆矩阵。根据输入神经网络的正负样本对的实际信息与网络对样本的预测信息，定义了表 4.1 所示的混淆矩阵形式：

TP：输入为正样本对，并且预测结果也是正样本

TN：输入为负样本对，并且预测结果也是负样本对

FP：输入为负样本对，预测为正样本对

FN：输入为正样本对，预测结果为负样本

表 4.1 混淆矩阵

预测值 / 实际值	预测为正	预测为负
实际为正	TP	TN
实际为负	FP	FN

TPR。TPR 又叫做召回率，它代表了正确预测为正类的数量占正实例的比例，根据混淆矩阵的参数，TPR 用式 4-1 表示：

$$TPR = \frac{TP}{TP + FP} \tag{4-1}$$

FPR。TPR 又叫做假正率，它代表了预测错误的正类数量占负实例的比例，根据混淆矩阵的参数，TPR 用式 4-2 表示：

$$FPR = \frac{FP}{FP + FN} \tag{4-2}$$

ROC 曲线。在一个二分类器中，通常会设定一个阈值，当判断的结果大于阈值，则为正类，小于阈值为负类，当阈值减小时，识别为正类的样本数增多，但同时会有更多的负样本识别为正类，ROC 曲线则能够形象地描述这种变化，常用于二分类器的性能评估。在 ROC 曲线空间中，横坐标为 FPR，纵坐标为 TPR，图中的每个点代表一种分类器，通过改变分类器阈值，完成 ROC 曲线的绘制。理想情况下，TPR 的值接近 1，FPR 接近 0，二分类器的性能最好。

AUC 值。ROC 曲线下的面积为 AUC 值。AUC 的值越大，分类器性能越好，如图 4.8 所示， AUC=1 分类器性能最好。

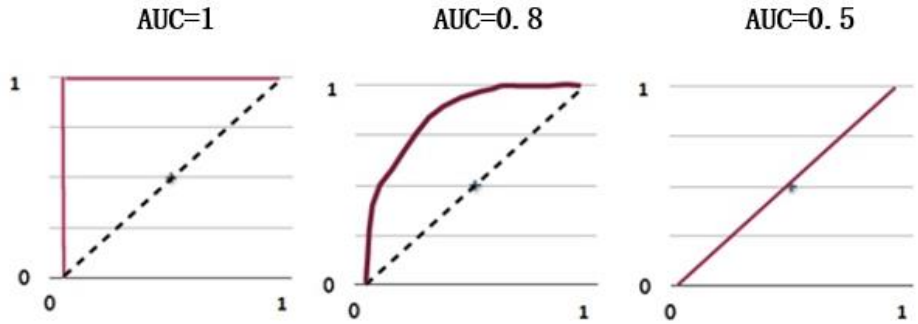

图 4.8 不同性能的分类器 AUC 值

4.3.2 性能分析

(1) ROC 曲线和 AUC 值

改变网络判断正负样的阈值从 1 到 0，记录 100 个阈值对应的网络的对相同样本测试的 TPR 和 FPR，得到的曲线如图 4.9 所示：

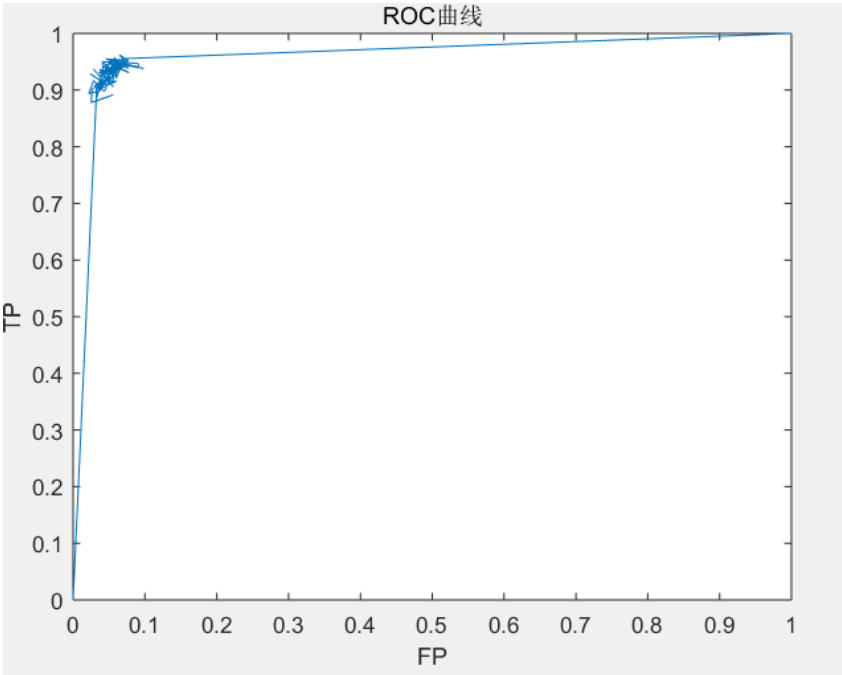

图 4.9 ROC 曲线

绘制的 ROC 曲线中，更多的点集中在左上角，AUC 的面积也接近为 1，训练的神经网络能实现实验目的。

(2) 与 SURF 算法比较

使用与 2.5.3 小节 SURF 算法实验相同的数据库对特征融合网络进行测试，并对两种算法的实验结果进行比较，特征融合网络性能远远好于基于 SURF 的匹配算法，适用性更强。

(3) 对图像噪声的抗干扰能力

在测试数据库上，分别叠加了高斯噪声和椒盐噪声，效果如表 4.2 所示：

其中：

$$\text{Accuracy}=\frac{TP+TN}{TP+TN+FP+FN} \tag{4-3}$$

$$q_{TP}=\frac{TP}{TP+FN} \tag{4-4}$$

$$q_{TN}=\frac{TN}{TN+FP} \tag{4-5}$$

$$q_{FP}=\frac{FP}{FP+TN} \tag{4-6}$$

$$q_{FN}=\frac{FN}{FN+TP} \tag{4-6}$$

表 4.2 对不同图像噪声的抗干扰能力

噪声	图像	Accuracy	q_{TP}	q_{TN}	q_{FP}	q_{FN}
原图像		94.8%	97%	90.2%	9.8%	3%
高斯噪声均值为 0 方差为 65		85.5%	96.8%	68%	32%	3.2%
椒盐噪声		70.1%	71.9%	60.7%	39.3%	28.1%

从表格中可以看出，对加入高斯噪声的图像，网络对正样本的匹配性能较好，出现的误检主要集中在将负样本识别为正样本；对加入椒盐噪声的图像，网络体现的抗干扰能力更差一些。分析原因在于，对网络进行训练的图片都没有加入噪声，测试图片与训练图片的物理结构存在差异，所以在加入噪声的测试集上性能并不是很好。

4.4 本章小结

本章主要是讲解第三章提出的特征融合网络的实验过程。由训练过程中的收敛曲线看出，网络很好地学习了输入样本的特征信息，并且网络中的 bn 层也极大地加快了收敛速度。通过绘制的 ROC 曲线和与基于 SURF 的匹配算法的比较，可以发现特征融合网络的有几乎完美的匹配性能。但是，在抗干扰能力方面，网络的性能还有待加强。

5 结论

本文对图像匹配技术进行了概述，阐述了图像匹配的基本原理和常用算法，并使用 SURF 算法对红外图像和可见光图像进行了实验，算法展现的性能不够好，所以提出了使用深度学习的方法来实现特征提取与匹配。接着介绍了深度学习的原理和深度学习的几种模型，重点讲解了卷积神经网络的结构，然后正式提出了能对红外图像和可见光图像精确匹配的特征融合网络。本文的结论主要有以下几点：

(1) 本文研究的基于深度学习的匹配方法，采用特征融合网络的中的卷积层进行特征提取，并对提取的特征进行融合决策，输出对输入样本的预测值。

(2) 绘制的 ROC 曲线表明训练好的特征融合网络具有较高的匹配性能。

(3) 与基于 SURF 的图像匹配算法相比，特征融合网络对红外外图像和可见光图像的匹配准确率较高，能够对与训练数据库物理结构相同的测试集进行几乎完美的匹配。

由于论文的研究时间和本身实力水平有限，针对红外图像与可见光图像的匹配还需进行进一步的研究，主要的改进方向如下：

(1) 本文实现了近红外图像与可见光的匹配，如果能够实现多种波段的红外图像与可见光图像匹配，尤其是中远红外图像与可见光的匹配，将有更大的实际意义。

(2) 本文设计的特征融合网络对不能有效的抑制噪声干扰，然而实际运用的图像可能存在各种类型的噪声，接下来需增大训练网络的数据库，向训练数据中加入含有噪声的图像，进一步提高网络的抗干扰能力

参考文献

[1] 王少武. 基于局部不变特征图像配准的研究[D].合肥工业大学,2013.

[2] 饶俊飞. 基于灰度的图像匹配方法研究[D].武汉理工大学,2005.

[3] 赵键. 点模式匹配算法研究[D].国防科学技术大学,2012.

[4] 宋伟东,朱琳.图像特征点提取及匹配技术研究[J].测绘与空间地理信息,2017,40(07):1-4.

[5] 李壮. 异源图像匹配关键技术研究[D].国防科学技术大学,2011.

[6] Harris C and Stephens M. A combined corner and edge detector[J]. Proceedings of the 4th Alvey Vision Conference, 1988:147-151.

[7] 苑津莎,赵振兵,高强,孔英会.红外与可见光图像配准研究现状与展望[J].激光与红外, 2009, 39(07):693-699.

[8] Bay H, Tuyte laars T, Gool L. SURF: Speeded Up Robust F eatures[C]/1 Proceed ings of the 9th European Confer2 ence Computer V ision, 2006: 404-417.

[9] 周莉莉,姜枫. 基于 FAST 和 BRIEF 的图像匹配算法[J]. 计算机工程与设计, 2015, 36(5): 1269-1273.

[10] 陈玉. 一种改进的 ORB 算法在图像匹配中的应用[J]. 微型机与应用, 2017(16):37-40.

[11] 戴涛,朱长仁,胡树平. 图像匹配技术综述[J]. 数字技术与应用, 2012(3): 174-175+177.

[12] 宋伟,刘洪亮,纳鹏宇,李明. 相似性测度函数分析及其在图像匹配中的应用研究[J]. 中央民族大学学报, 2014,23(1):45-51.

[13] 王军,张明柱. 图像匹配算法的研究进展[J]. 大气与环境光学学报,2007,2(1):11-15.

[14] 王文胜,翟尚礼,白俊奇. 基于 SSDA 的图像匹配跟踪算法[J]. 指挥信息系统与技术, 2016,7(6) :77-80.

[15] 郑刚. 基于特征的图像匹配算法研究[D]. 国防科技大学；2011 年.

[16] 储蓄. 基于改进 SURF 算法图像匹配方法研究[D]. 安徽理工大学;2017.

[17] P Viola, M Jones. Rapid Object Detection using a Boosted Cascade of Simple[C]. Computer Vision and Pattern Recognition, Proceedings of the 2001 IEEE Computer Society Conference On, Kauai Marriott，Hawaii，CVPR, 2001:511-518.

[18] 杨冬蕾. 针对图像特征提取算法的并行加速研究[D].复旦大学,2013.

[19] 殷琪林,王金伟. 深度学习在图像处理领域中的应用综述[J]. 高教学刊,2018(9):72-74.

[20] Hinton, Geoffrey E, Simon Osindero, and Yee-Whye Teh. A fast learning algorithm for deep belief nets[J]. Neural computation, 2006 (18)：1527-1554.

[21] 曾安,张艺楠,潘丹,Xiao-Wei Song.基于稀疏降噪自编码器的深度置信网络[J].计算机应用,2017,37(09):2585-2589.

[22] Hinton G. Training Products of Experts by Minimizing Contrastive Divergence[J], Neural Computation, 2002(8)：1771-1800.

[23] Won Y, Gader P, Coffield P. Morphological Shared-weight Networks with Applications to Automatic Target Recognition[C]//Proceedings of the International Conference on Neural Networks. IEEE, 1997, 8(5)：1195-1203.

[24] Serre T, Riesenhuber M, Louie J, et al. On the Role of Object-specific Features for Real World Object Recognition in Biological Vision[C]//Biologically Motivated Computer Vision. IEEE, 2002：387-397.

致谢

本论文是在指导老师朱敏老师的精心指导下完成的，从开始的选题立意到框架结构到最后实验设计和论文书写，他们不仅提出了很多宝贵的建议，而且为我答疑解惑，从而使我能顺利的完成本文。从他们身上，我学到了专业知识以及科学的研究方法，体会到了他们认真负责的治学态度和精益求精的学术作风。学无止境，我们要学的、能学的不只是知识，更是学习的能力和个人品格的培养。

此外，我还要感谢实验室中一直帮助我的师兄们，在遇到难题时和他们的互相探讨，他们给予的帮助，对我完成此论文有很大帮助。

寒窗苦读十余年，感谢父母和亲人多年的培养和支持，感谢同窗好友的相互扶持。转眼间大学阶段学习已经快要结束，我也即将迈入人生新的征程，在这里衷心祝愿我的母校合肥工业大学能够在未来不断奋进，跨入我国顶尖学府的行列。在未来的人生道路上，我一定会不忘初心，砥砺前行，为了实现自己的人生理想不懈奋斗！

作者：化彦伶

2018 年 6 月 7 日